STA 3402 – Machine Learning & Neural Networks

Lecture 1 (Day 1) – පාඨමාලාවට හැඳින්වීම සහ Statistical Learning නැවත මතක් කිරීම

කථිකාචාර්ය: Dr. Samir, සංඛ්‍යාන අධ්‍යයන අංශය, කොළඹ විශ්වවිද්‍යාලය

Lecture recording එක, whiteboard එක සහ R code එක භාවිතා කර සකස් කළ සම්පූර්ණ සටහන් (සරල සිංහලෙන්)

මේ සටහන කියවන විදිහ

තාක්ෂණික වචන (technical terms) exam එකේදී සහ code එකේදී ඉංග්‍රීසියෙන්ම එන නිසා, ඒවා ඉංග්‍රීසියෙන්ම තියලා, තේරුම සිංහලෙන් දීලා තියෙනවා. රූපවල labels ඉංග්‍රීසියෙන් තියෙන්නේ ඒ නිසාමයි.

පටුන

1. පාඨමාලා තොරතුරු සහ පන්තියේ නීති
2. Syllabus එක – අපි ඉගෙන ගන්නේ මොනවද
3. AI, Machine Learning සහ Deep Learning
4. Supervised learning (regression සහ classification)
5. Unsupervised learning (clustering සහ recommender systems)
6. දත්ත ගැටලුවක් විසඳන පියවර (ගෙවල් මිල උදාහරණය)
7. Data preprocessing: duplicates, dummy coding, missing values, outliers, scaling
8. Exploratory Data Analysis (EDA)
9. Train / test split
10. Regression ගැටලුවකට භාවිතා කළ හැකි models
11. වැදගත් වචන: predictors, response, multicollinearity
12. Linear regression, Ridge සහ Lasso (regularization)
13. Decision trees සහ Random Forest
14. Variable selection සහ variable importance plot
15. Dimension reduction – PCA
16. කථිකාචාර්යතුමාගේ career උපදෙස්
17. R practical – mtcars උදාහරණය (code එක පේළියෙන් පේළිය)
18. Assignment 1 – Kaggle competition
19. සාරාංශය සහ පුනරීක්ෂණ ප්‍රශ්න

1. පාඨමාලා තොරතුරු සහ පන්තියේ නීති

කරුණ	විස්තරය
Lecture වේලාව	සඳුදා, ප.ව. 6.00 – 9.00, online (Zoom). සමහර සතිවල සඳුදා පන්තිය ගන්න බැරි වුණොත් වෙනත් දවසක අමතර පන්තියක් තියෙනවා (උදා: පළමු සතියේ **බදාදා ප.ව. 6ට**; R file එකේ බදාදා ප.ව. 7 කියලා තියෙනවා – WhatsApp group එක බලන්න).
Lab sessions	Lab sessions ත් තියෙනවා. Labs reserve කළාම වේලාව දැනුම් දෙනවා. ඔයාලා lab එකට ගිහින් lab sheet එක කරන්න ඕන.
Credits	**Credits 4යි**. න්‍යායාත්මකව සතියකට පැය 4ක් හමුවිය යුතුයි. නමුත් lab sessions තියෙන නිසා online **සතියකට පැය 2–3ක්** පමණ හමුවෙනවා.
ඇගයීම	Take-home assignments සහ in-class assignments තියෙනවා. Syllabus එකට අනුව (credit 4 subject එකක සාමාන්‍ය ක්‍රමය) **අඛණ්ඩ ඇගයීම 40% + අවසාන විභාගය 60%** පමණ. (පසුගිය Statistical Learning subject එකේ කාලසටහන නිසා assignments තිබුණේ නැහැ – written සහ lab කොටස් සහිත final exam එක විතරයි කියලා ශිෂ්‍යයෝ කිව්වා.)
Materials	**Google Drive** link එකක් හරහා (LMS access තවම නැති නිසා). Link එක WhatsApp group එකෙත් තියෙනවා.
Software	ප්‍රධාන වශයෙන් **R / RStudio**. Lab computers වල RStudio install කරලා තියෙනවා.

පන්තියේ නීති

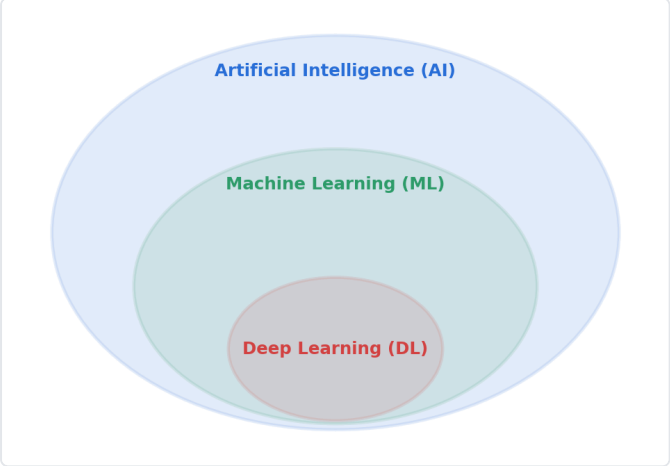
- **පැමිණීම (attendance)** ගන්නේ Zoom නමෙන්. දීලා තියෙන format එකට (registration number + නම) නම වෙනස් කරන්න. එක laptop එකකින් දෙන්නෙක් join වෙනවා නම් දෙන්නගෙම නම් දාන්න.
- ප්‍රශ්නයකට උත්තර දෙන්න **thumbs-up** button එක, **chat** එක, නැත්නම් unmute කරලා කතා කරන්න පුළුවන්.
- මේක ගොඩක් **practical** subject එකක්. Lecture එක අතරතුර code run කරන නිසා ලබන සතියේ ඉඳන් phone එකෙන් නෙවෙයි, **laptop / desktop** එකකින් join වෙන්න.
- මොකක් හරි අපහසුතාවයක් තියෙනවා නම් (උදා: රෑ 9ට ඉවර වෙන එක පරක්කු නම්) WhatsApp එකෙන් lecturer ට කියන්න.

2. Syllabus එක – අපි ඉගෙන ගන්නේ මොනවද

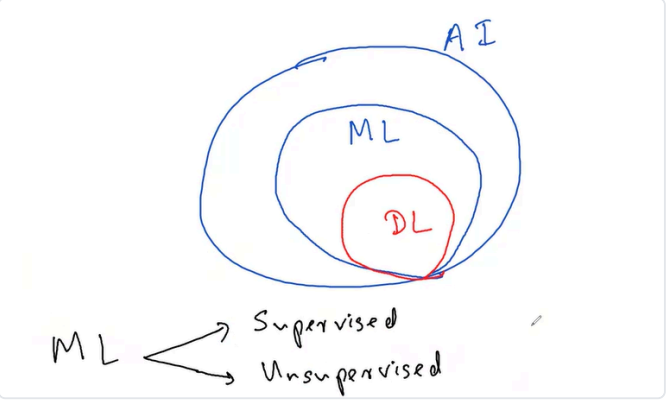
ප්‍රධාන කොටස	මාතෘකා
Neural networks (module එකේ නමම වන ප්‍රධාන මාතෘකාව)	Neuron එකක ජීව විද්‍යාත්මක ක්‍රියාකාරිත්වය; neural network මූලික කරුණු; back-propagation algorithm; associative learning; pattern recognition, (signal/image) processing සහ computer vision සඳහා learning algorithms.
Supervised learning	Parametric algorithms; Support Vector Machines (SVM); kernels; neural networks.
Unsupervised learning	Clustering; dimension reduction; recommender systems.
Deep learning සහ reinforcement learning	Deep learning; reinforcement learning – agent, environment, ඒ ආශ්‍රිත ගැටලු සහ Markov decision process.

අද lecture එක **Statistical Learning (පසුගිය semester)** නැවත මතක් කිරීමක්. ඉදිරි පාඩම් වලට මේවා අවශ්‍ය වෙනවා.

3. AI, Machine Learning සහ Deep Learning



පැහැදිලි රූපසටහන



Lecturer ගේ whiteboard එක

- **Artificial Intelligence (AI – කෘත්‍රිම බුද්ධිය)** – ලොකුම ක්ෂේත්‍රය: computers වලට "බුද්ධිමත්" වැඩ කරවීම.
- **Machine Learning (ML)** – AI වල **උප කොටසක් (subset)**. Computer එකට ස්ථිර නීති දෙනවා වෙනුවට, **දත්ත වලින් රටා (patterns) ඉගෙන ගන්නවා**.
- **Deep Learning (DL)** – ML වල **උප කොටසක්**. Layers ගොඩක් තියෙන neural networks භාවිතා කරනවා.

ඒ කියන්නේ: හැම DL ක්‍රමයක්ම ML, හැම ML ක්‍රමයක්ම AI – නමුත් අනිත් පැත්තට නෙවෙයි.

Machine learning වල **ප්‍රධාන වර්ග දෙකක්** තියෙනවා:

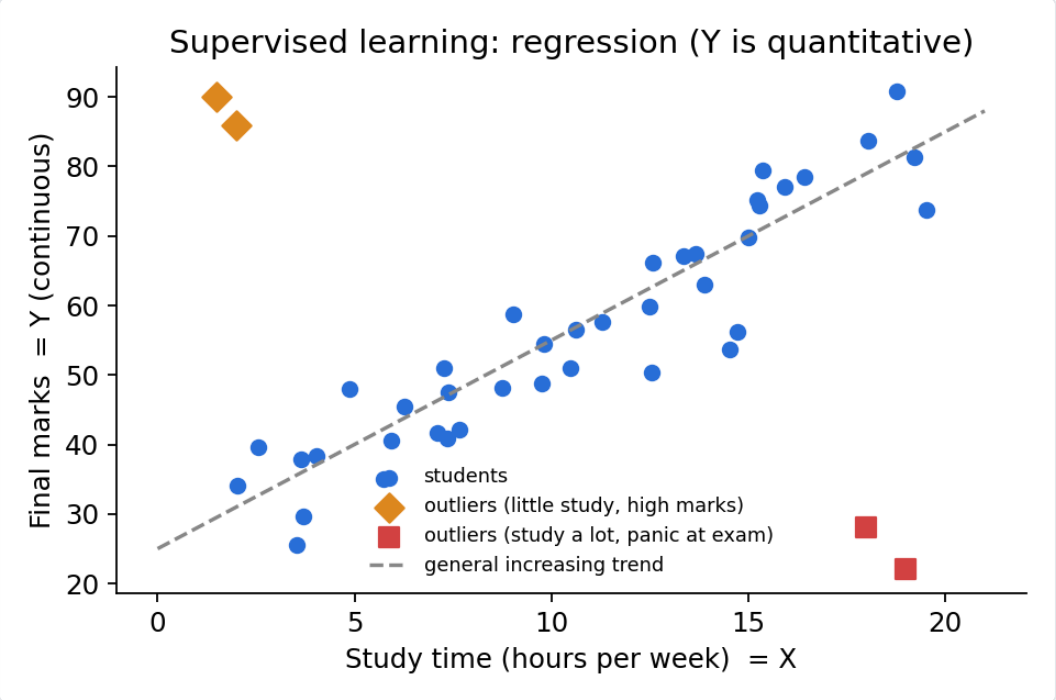
Supervised learning	Unsupervised learning
Response (target / Y) variable එකක් තියෙනවා. X variables වලින් Y අනුමාන (predict) කරන්න model එක ඉගෙන ගන්නවා.	**Response variable එකක් නැහැ.** X variables අතර රටා හෝ කණ්ඩායම් විතරක් හොයනවා.
ශිෂ්‍යයෝ දුන්න උදාහරණ: mobile phone මිල prediction, එළවළු මිල models, regression models, classification trees.	උදාහරණ: clustering, recommender systems, dimension reduction.

4. Supervised learning

4.1 උදාහරණ 1 – පාඩම් කරන කාලය සහ අවසාන ලකුණු (regression)

අපේ data set එකේ columns තුනක් තියෙනවා කියමු: **Registration number (ID)**, **Study time** (මේ subject එකට සතියකට පාඩම් කරන පැය ගණන) සහ **Final marks**.

ID	Study time (පැය/සතිය)	Marks
1	15	80
2	3	35
…	…	…



Study time එදිරිව marks – සාමාන්‍යයෙන් වැඩිවන රටාවක්, outliers කිහිපයක් සමඟ

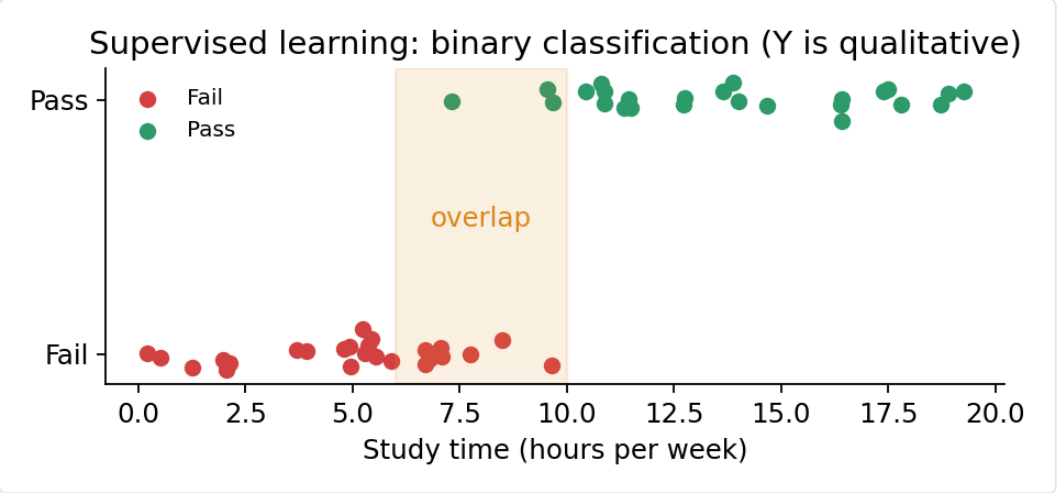
Data plot කළාම සාමාන්‍යයෙන් පේන දේ:

- මහන්සි වෙලා වැඩ කරන ශිෂ්‍යයෝ සතියකට පැය 15–20ක් පාඩම් කරනවා, ඒ අයගෙන් වැඩි දෙනෙක්ට **හොඳ ලකුණු**.
- කාර්යබහුල අය (part-time job, සම්බන්ධතා, ආදිය) අඩුවෙන් පාඩම් කරනවා, **අඩු ලකුණු** ගන්නවා.
- සාමාන්‍ය ශිෂ්‍යයෝ සාමාන්‍ය කාලයක් පාඩම් කරලා **සාමාන්‍ය ලකුණු** ගන්නවා.

- සමහරු exam එකට කලින් පැය 1–2ක් විතරක් පාඩම් කරලා ගොඩක් **ඉහළ** ලකුණු ගන්නවා. තවත් සමහරු හැමදාම පාඩම් කරලත් **exam එකේදී බය වෙලා (panic)** අඩු ලකුණු ගන්නවා. මේ වගේ අසාමාන්‍ය points වලට **outliers** කියනවා.

සාමාන්‍යයෙන් **වැඩිවන රටාවක් (increasing trend)** තියෙනවා. මෙතන **marks කියන්නේ continuous (quantitative – සංඛ්‍යාත්මක) variable එකක්**. ඒක **Y variable** = response = target = dependent variable. Y variable එකක් තියෙන නිසා මේක **supervised learning** (regression ගැටලුවක්).

4.2 උදාහරණ 2 – Pass ද Fail ද (classification)



Y ට categories දෙකක් විතරයි → binary classification

දැන් response එක **grade එක: Pass හෝ Fail**. අඩුවෙන් පාඩම් කරන අය සාමාන්‍යයෙන් fail, වැඩියෙන් පාඩම් කරන අය pass, මැද කොටසේ දෙපැත්තම මිශ්‍ර වෙනවා (overlap).

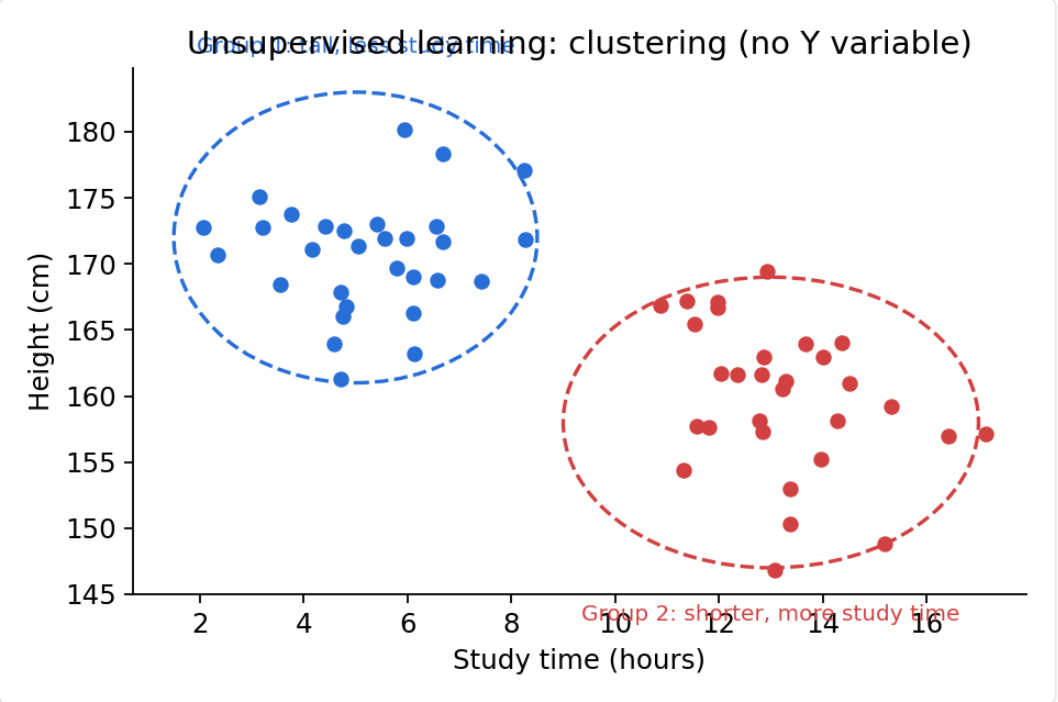
- Response එක **qualitative (categorical – ගුණාත්මක)**, categories දෙකයි → **binary classification** ගැටලුවක්.
- තවමත් response variable එකක් තියෙන නිසා **මේකත් supervised learning**.

> **මතක තියාගන්න**
> Y සංඛ්‍යාවක් නම් (උදා: marks, මිල) → **regression**. Y category එකක් නම් (උදා: pass/fail) → **classification**. දෙකම **supervised**.

5. Unsupervised learning

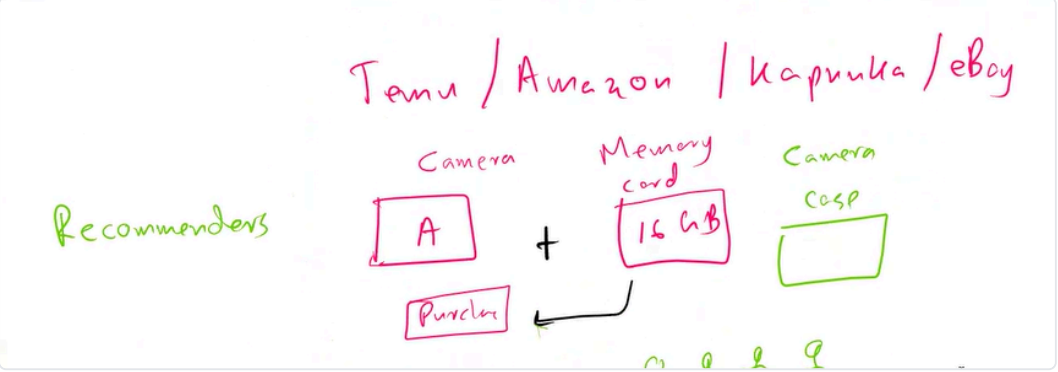
5.1 Clustering

මෙතන **response variable එකක් නැහැ**. අපි ලක්ෂණ කිහිපයක් විතරක් මනිනවා, උදා: **study time** සහ **උස (height)**. Marks response එකක් විදිහට ගන්නේ නැහැ. Plot කළාම **කණ්ඩායම් (clusters)** පේන්න පුළුවන් – උදා: එක කණ්ඩායමක් උසයි, අඩුවෙන් පාඩම් කරනවා (සමහරවිට පිරිමි ළමයි), අනිත් කණ්ඩායම මිටියි, වැඩියෙන් පාඩම් කරනවා (සමහරවිට ගැහැණු ළමයි). මේ වගේ කණ්ඩායම් හොයන එක **clustering** – ඒක **unsupervised learning**.



Y variable එකක් නැහැ – data වල ස්වාභාවික කණ්ඩායම් හොයනවා

5.2 Recommender systems (නිර්දේශ පද්ධති)



Whiteboard: online shops සම්බන්ධිත භාණ්ඩ නිර්දේශ කරනවා

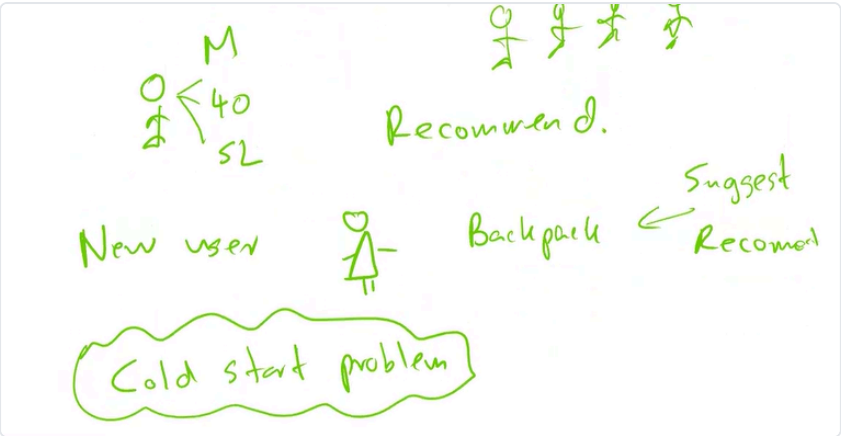
Temu, Amazon, Kapruka, eBay වගේ online shop එකකින් මොනවා හරි ගන්නකොට:

- ඔයා **camera එකක් (item A)** cart එකට දානවා / මිලදී ගන්නවා.
- Site එක "camera එකක් ගත්ත අය **16 GB memory card** එකකුත් ගත්තා" කියලා ඒක යෝජනා කරනවා.
- ඊළඟ පාර **camera case** එකක් යෝජනා කරන්න පුළුවන්.

මේක **recommender system** එකක්. සමාගමට ඔයා ගැන දන්නවා වෙන්න පුළුවන් (උදා: පිරිමි, වයස 40, ශ්‍රී ලංකාවේ ජීවත් වෙනවා), ඔයාගේ **පරණ මිලදී ගැනීම්**, සහ **ඔයා වගේ වෙනත් අය** ගත්ත දේවල්. ඒවා ගළපලා **නිර්දේශ (recommend / suggest)** කරනවා.

Netflix තවත් උදාහරණයක්: ඔයා film එකක් බැලුවාම (උදා: X-Men film එකක්) ඊළඟ film එක යෝජනා කරනවා. අවුරුදු කිහිපයකට කලින් Netflix එයාලගේ recommender system එක දියුණු කරන කෙනෙකුට ඩොලර් මිලියනයක් පමණ ත්‍යාගයක් දෙන තරඟයක් (**Netflix Prize**) පැවැත්වුවා. Internet එකේ හොයලා බලන්න.

5.3 Cold start problem (සීතල ආරම්භ ගැටලුව)

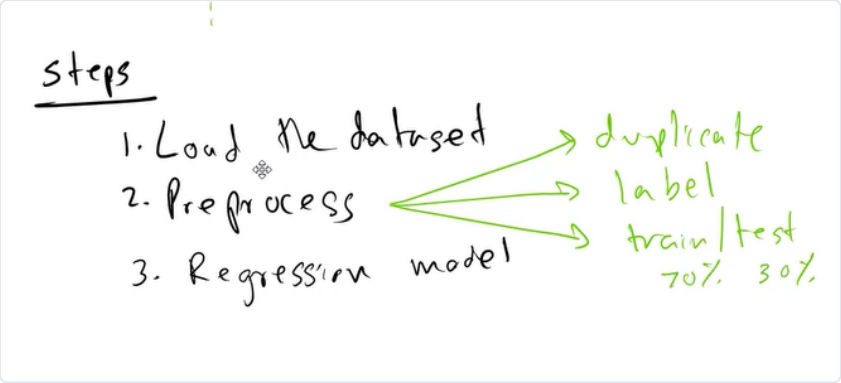


Whiteboard: අලුත් user කෙනෙකුට ඉතිහාසයක් නැහැ

අලුත් user කෙනෙක් join වෙලා **backpack** එකක් ගන්න හදනවා. සමාගම ළඟ මේ කෙනා ගැන **කිසිම පරණ දත්තයක් නැහැ**, නමුත් තවමත් යමක් නිර්දේශ කරන්න ඕන (සපත්තු, තවත් bag එකක්, ...). දත්ත නැතුව නිර්දේශ කරන්නේ කොහොමද? මේ අපහසුතාවයට **cold start problem** කියනවා. පර්යේෂකයෝ තවමත් මේ ගැන වැඩ කරනවා.

6. දත්ත ගැටලුවක් විසඳන පියවර

උදාහරණය: Boston house data set එක. ID එකක්, ගෙදර ප්‍රමාණය **square feet** වලින්, තවත් variables ගොඩක්, සහ ගෙදර **මිල (price)** තියෙන CSV file එකක් දීලා තියෙනවා. **අරමුණ: මිල අනුමාන (predict) කරන** model එකක් හදන්න. මිල තමයි **target variable** එක.



Whiteboard: ශිෂ්‍යයෝ යෝජනා කළ පියවර

පන්තිය යෝජනා කළ, lecturer සම්පූර්ණ කළ පියවර:

1. **Data set එක load කිරීම** (data දීලා තියෙන නිසා එකතු කරන්න ඕන නැහැ).
2. **Data pre-process කිරීම**:
   - **duplicate** (දෙවරක් ඇති) records ඉවත් කිරීම
   - අවශ්‍ය නම් data **label** කිරීම
   - **missing values** (නැති අගයන්) හැසිරවීම
   - **outliers** හැසිරවීම
   - data **normalize** හෝ **standardize** කිරීම (rescale)
   - categorical variables සඳහා **dummy coding**

3. **Exploratory Data Analysis (EDA)** – plots සහ summaries.
4. Training සහ testing sets වලට **බෙදීම (split)** (70:30 හෝ 80:20).
5. Training set එක මත **සුදුසු model එකක් fit කිරීම** (උදා: regression model එකක්).
6. Test set එකෙන් model එක **පරීක්ෂා කිරීම**, error එක මැනීම, උදා: **MSE (mean squared error)**.

7. Data preprocessing

7.1 Dummy coding (categories → අංක)

Models වලට අංක ඕන නිසා **categorical variable** එකක් අංක ආකාරයට හරවනවා.

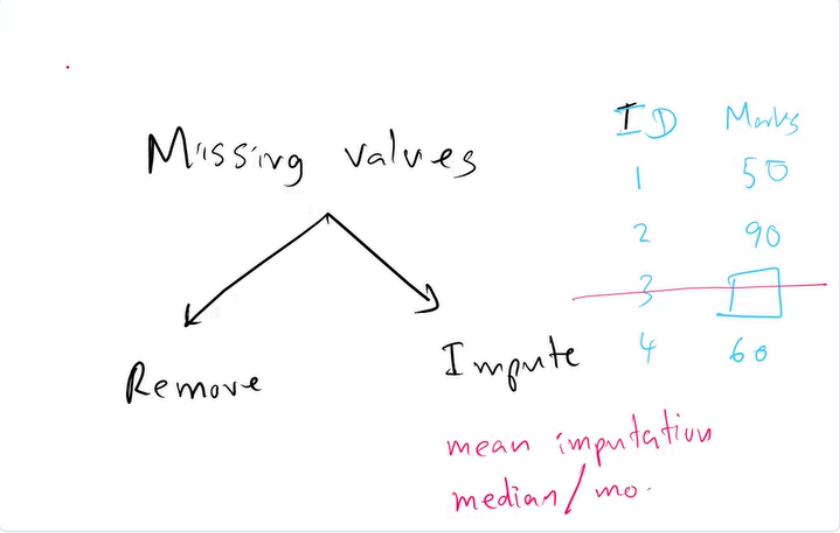
ස්ත්‍රී/පුරුෂ භාවය (Gender): Male = 1, Female = 0.

අධ්‍යාපන මට්ටම (levels 4):

අධ්‍යාපන මට්ටම	Code
පශ්චාත් උපාධි සුදුසුකම්	1
BSc	2
A/L	3
A/L ට අඩු	0 (reference level)

Regression වලදී parameters ගණනය කරන්න **indicator (dummy) variables** හදනවා. එක level එකක් **reference level (0)** විදිහට ගන්නවා – සමහර tools අන්තිම level එක ගන්නවා, සමහර ඒවා පළමු level එක ගන්නවා. Machine learning tools වලටත් මේ වගේ අංක ආකාරය ඕන.

7.2 Missing values (නැති අගයන්)



Whiteboard: ඉවත් කරන්න හෝ impute කරන්න

විකල්ප දෙකක් තියෙනවා:

1. **Remove (ඉවත් කිරීම)** – missing value එක තියෙන පේළිය මකා දැමීම (R වල උදා: `na.omit()`).
2. **Impute (පිරවීම)** – නැති අගය වෙනුවට සාධාරණ අගයක් කෘත්‍රිමව දැමීම.

ID	Marks
1	50
2	90
3	**නැහැ (missing)**
4	60

- **Remove:** 3 වන පේළිය මකනවා.
- **Mean imputation:** මධ්‍යන්‍යය = (50 + 90 + 60) / 3 = 200 / 3 = **66.67** → 3 වන පේළියට 66.67 දානවා.
- **Median imputation:** මධ්‍යස්ථය (median) දානවා (outliers තියෙනකොට හොඳයි). 50, 60, 90 වල median = 60.
- **Mode imputation: categorical** variable එකකට, වැඩිපුරම තියෙන category එක දානවා.

> **ප්‍රායෝගික නීතිය (lecture එකෙන්)**
>
> - Missing ප්‍රමාණය 5–10% ට අඩු නම් → ඒ පේළි **ඉවත් කරන්න** පුළුවන්.
> - Missing 10–20% පමණ නම් → **impute** කරන්න.
> - Missing 50% ට වැඩි නම් → **ඒ variable එකම ඉවත් කරන්න**. අගයන් වැඩි ප්‍රමාණයක් අපි දැමුවොත් අපි වැඩ කරන්නේ කෘත්‍රිම variable එකක් එක්ක, ඒ නිසා තියාගෙන වැඩක් නැහැ.

7.3 Outliers (අසාමාන්‍ය අගයන්)

Outlier එකක් කියන්නේ අනිත් අගයන්ට වඩා ගොඩක් දුරින් තියෙන අගයක්. Plot එකක් ඇහැට බැලීම ("eyeballing") උදව් වුණත් තීරණය කරන්න විශ්වාසදායක ක්‍රමයක් නෙවෙයි. වඩා හොඳ ක්‍රමය **IQR method** එක (box plot එකත් මේකම භාවිතා කරනවා). Box plot එකක outliers පෙන්නන්නේ **රවුම් හෝ තරු (asterisks)** වලින්.

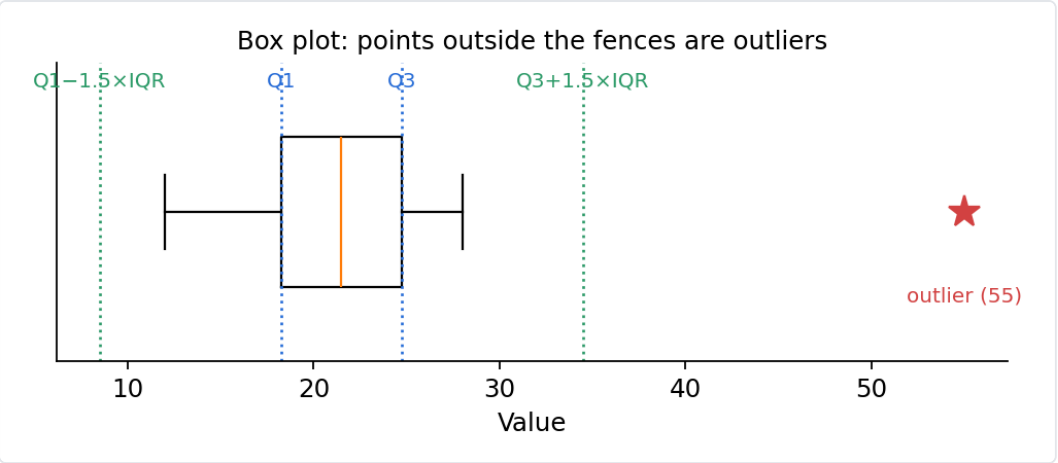
$$\text{IQR} = Q3 - Q1$$

$$\text{අවම සාමාන්‍ය අගය (lower fence)} = Q1 - 1.5 \times \text{IQR}$$

$$\text{උපරිම සාමාන්‍ය අගය (upper fence)} = Q3 + 1.5 \times \text{IQR}$$

Lower fence එකට අඩු හෝ upper fence එකට වැඩි ඕනෑම අගයක් outlier එකක්.

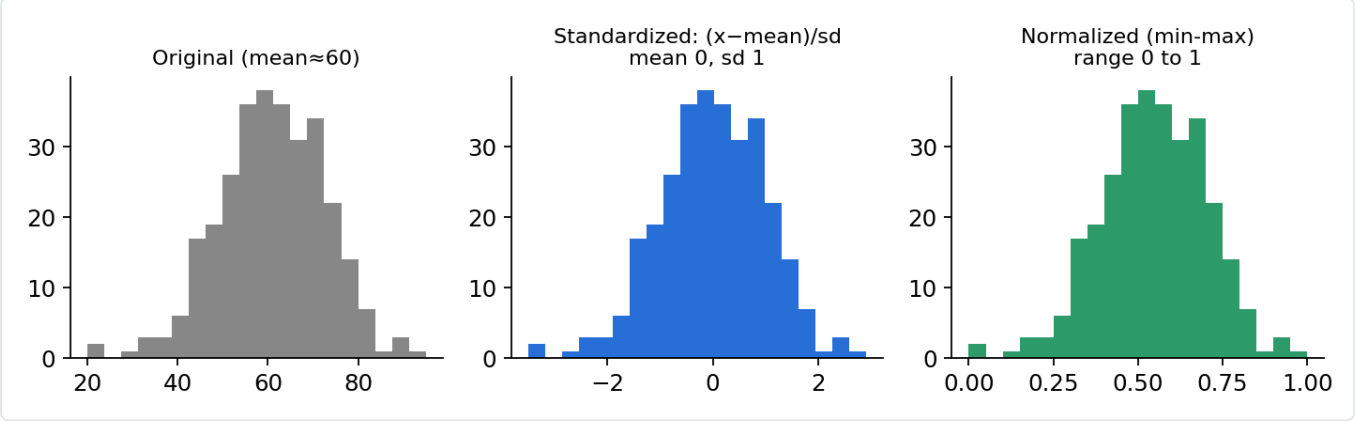
> **පියවරෙන් පියවර උදාහරණය**
>
> Data: 12, 15, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 28, 55
> පියවර 1: Q1 = 18.25, Q3 = 24.75 (R: `quantile(x)`)
> පියවර 2: IQR = 24.75 − 18.25 = 6.5
> පියවර 3: 1.5 × IQR = 9.75
> පියවර 4: Lower fence = 18.25 − 9.75 = 8.5; Upper fence = 24.75 + 9.75 = 34.5
> පියවර 5: 55 > 34.5, ඒ නිසා **55 outlier එකක්**. අනිත් හැම අගයක්ම 8.5 ත් 34.5 ත් අතර.



7.4 Scaling: standardization සහ normalization

Variables **වෙනස් ඒකක (units)** වලින් තියෙනකොට (උදා: square feet සහ කාමර ගණන) ඒවායේ විසිරීම ගොඩක් වෙනස්. ඒ නිසා **rescale** කරනවා.

	Standardization	**Normalization (min-max)**
භාවිතා කරන්නේ කවදද	Data දළ වශයෙන් **normal** නම්	Data **normal නැත්නම්**
සූත්‍රය	z = (x − mean) / standard deviation	x' = (x − min) / (max − min)
ප්‍රතිඵලය	mean 0, standard deviation 1	අගයන් 0 ත් 1 ත් අතර
උදාහරණය	mean 60, sd 10, x = 75 → z = 15/10 = 1.5	min 20, max 100, x = 60 → 40/80 = 0.5

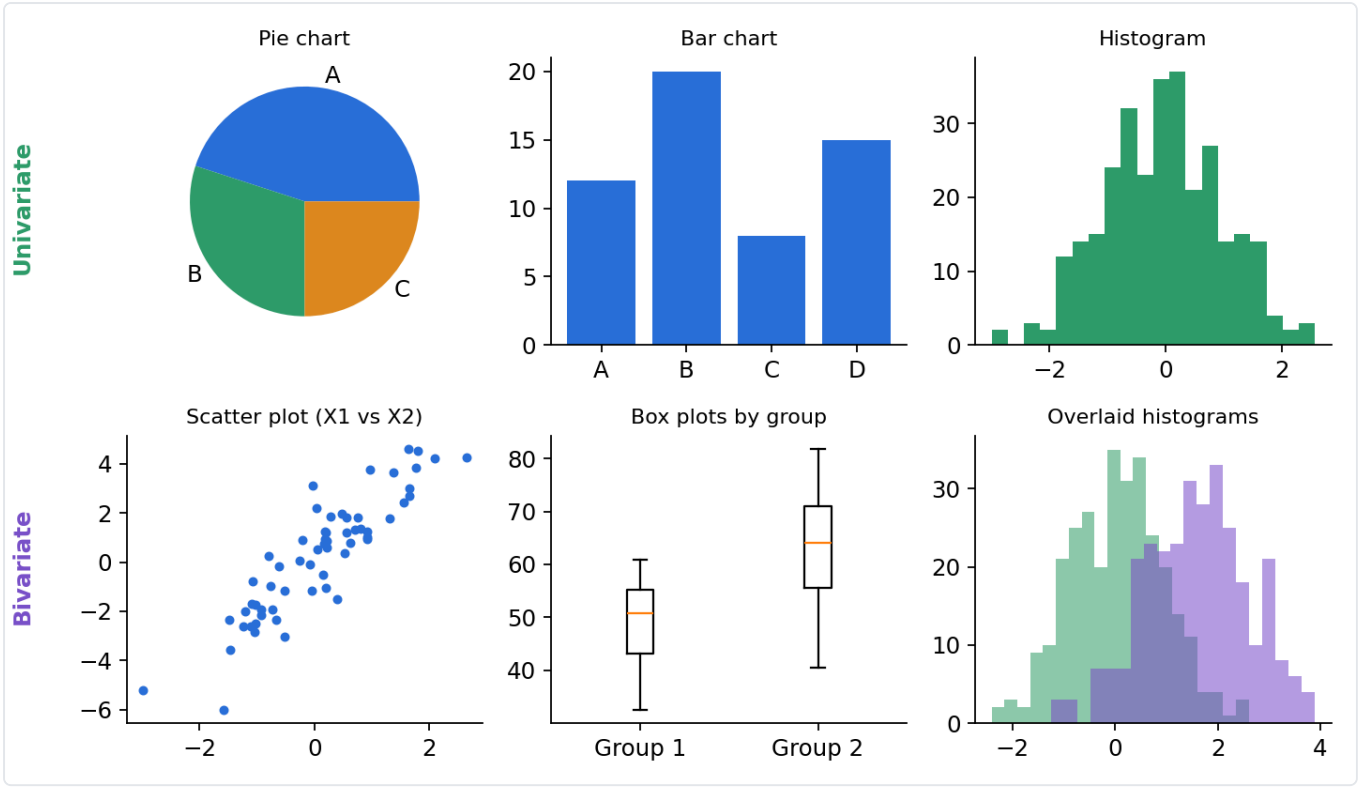


හැඩය එහෙමමයි; වෙනස් වෙන්නේ පරිමාණය (scale) විතරයි

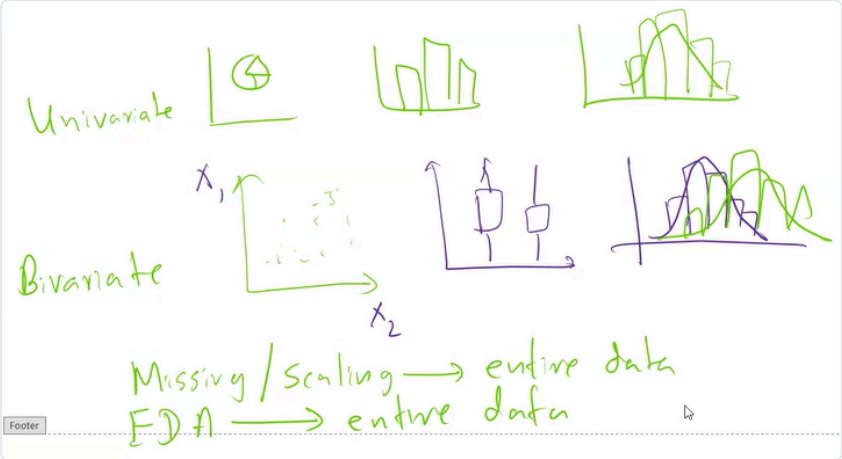
8. Exploratory Data Analysis (EDA)

EDA කියන්නේ modelling කරන්න කලින් variables තේරුම් ගන්න plots සහ summaries වලින් data බැලීම.

- **Univariate** (එක variable එකක් බැගින්): pie charts, bar charts, histograms.
- **Bivariate** (variables දෙකක් එකට): scatter plots (X1 එදිරිව X2, හෝ X එදිරිව response), කණ්ඩායම් අනුව box plots, එකිනෙක මත දැමූ histograms (overlaid).

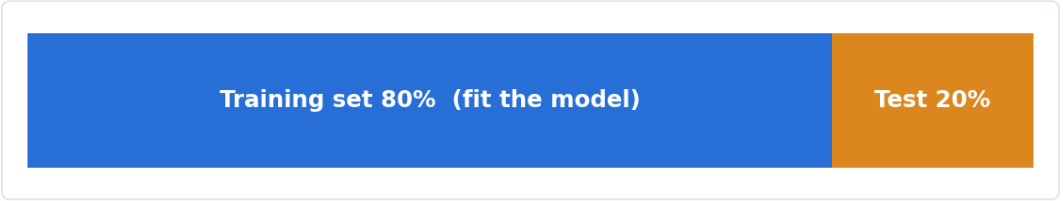


බහුලව භාවිතා වන EDA plots



Whiteboard version එක

9. Train / test split

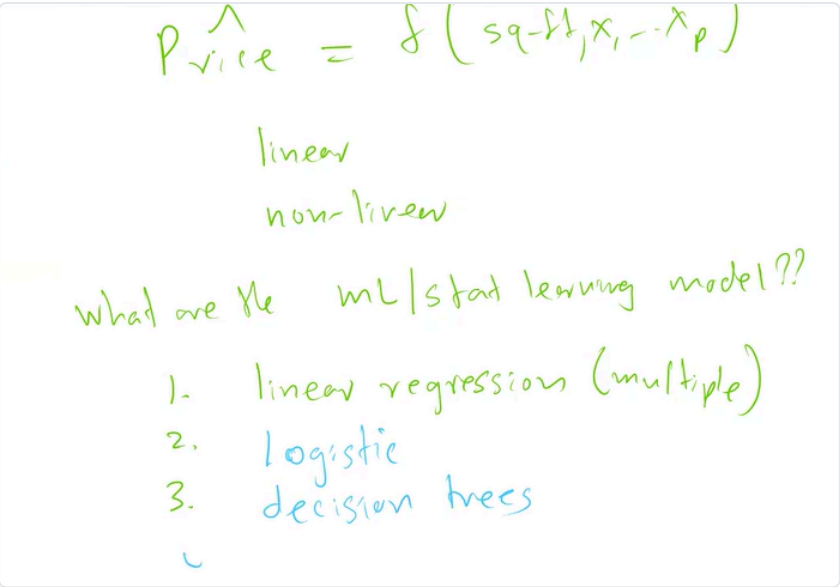


- Data **training set** එකකට (model එක fit කරන්න) සහ **test set** එකකට (අලුත් data වලට model එක කොච්චර හොඳට predict කරනවද බලන්න) බෙදනවා. සාමාන්‍ය අනුපාත: **80:20** හෝ **70:30**.
- **ක්‍රම දෙකක්:**

1. Missing value imputation, outlier detection, scaling සහ EDA **සම්පූර්ණ data set එකටම** කරලා, පස්සේ split කරනවා. එතකොට train සහ test sets දෙකේම missing values නැහැ.
2. Scaling ආදිය train සහ test වලට **වෙන වෙනම** කරනවා. මේක වඩා සංකීර්ණයි: උදා: test set එකට training set එකේ mean සහ variance ද, නැත්නම් සමස්ත mean එකද පාවිච්චි කරන්නේ? මේ ගැන විවාද තියෙනවා.

> **මේ පාඨමාලාවට**
> Missing values, scaling, outlier detection සහ EDA **සම්පූර්ණ data set එකටම** කරන්න, **ඊට පස්සේ** train සහ test වලට බෙදලා training set එක මත model එක train කරන්න.

10. Regression ගැටලුවකට models



Whiteboard: මිල X variables වල function එකක් ලෙස

මිල අනිත් variables වල function එකක් විදිහට model කරන්න ඕන:

$$\text{Price} = f(\text{sq-ft}, X_1, \ldots, X_p)$$

f function එක **linear (රේඛීය)** හෝ **non-linear** වෙන්න පුළුවන්. Y අංකයක් (මිල) වන විට භාවිතා කළ හැකි machine / statistical learning models:

- Multiple linear regression
- Polynomial regression / වෙනත් non-linear regression
- Decision (regression) trees
- Random forest
- Support vector regression (SVR)
- XGBoost
- KNN regression
- Ridge / Lasso regression (regularization)

බහුලව කරන වැරැද්ද
සමහර ශිෂ්‍යයෝ **logistic regression** කිව්වා (whiteboard එකෙත් තියෙනවා). නමුත් මිල **quantitative** variable එකක්. Logistic regression සහ linear discriminant analysis (LDA) **classification** සඳහා, ඒ නිසා මිල predict කරන්න ඒවා **භාවිතා කරන්න බැහැ**.

11. වැදගත් වචන

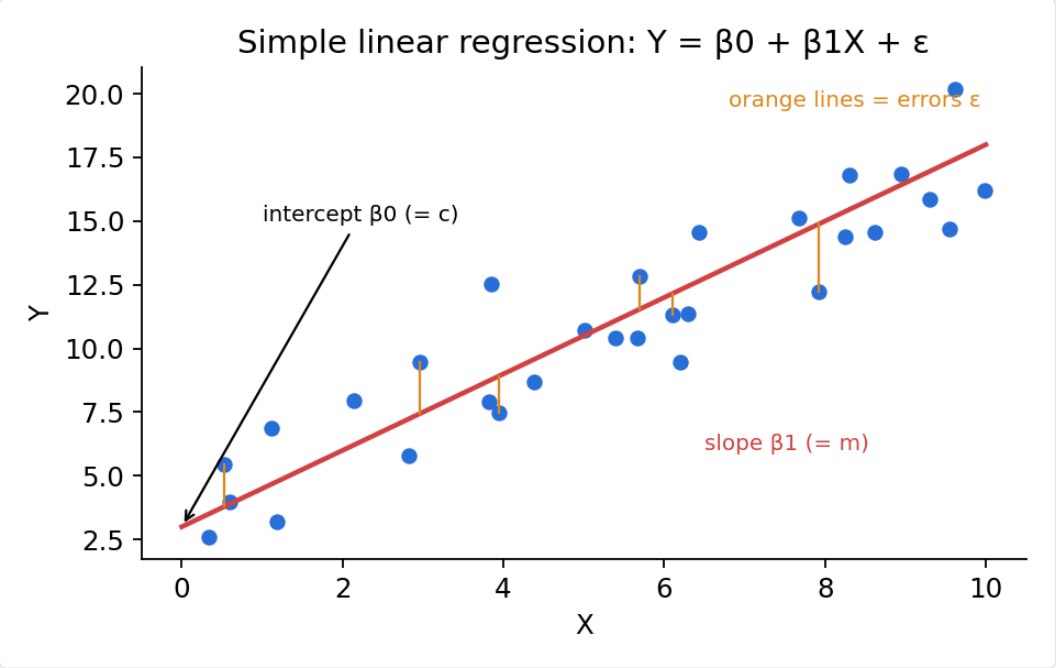
වචනය	තේරුම
X variables	Predictors / independent variables (ස්වාධීන විචල්‍ය) / explanatory variables
Y variable	Target / response / dependent variable (පරායත්ත විචල්‍යය) (සමහර වෙලාවට "label" කියනවා)
Multicollinearity	**X variables එකිනෙකට සම්බන්ධ (correlated) වීම**. Y, X1, X2, ... එක්ක සම්බන්ධ වෙයි කියලා අපි බලාපොරොත්තු වෙනවා, නමුත් සමහර විට X1, X2, ... තමන් අතරත් සම්බන්ධයි. මේක regression වලට ගැටලු ඇති කරනවා.

12. Linear regression, Ridge සහ Lasso

12.1 Simple linear regression

ගණිතයේ සරල රේඛාවක් **y = mx + c** (c = intercept – අන්තඃඛණ්ඩය, m = slope – අනුක්‍රමණය). සංඛ්‍යානයේදී ග්‍රීක අකුරු භාවිතා කරලා, රේඛාව මත නැති points හසුරුවන්න error term එකක් එකතු කරනවා:

$$Y = \beta_0 + \beta_1 X + \varepsilon$$



12.2 Multiple linear regression

X variable එකකට වඩා තියෙනකොට:

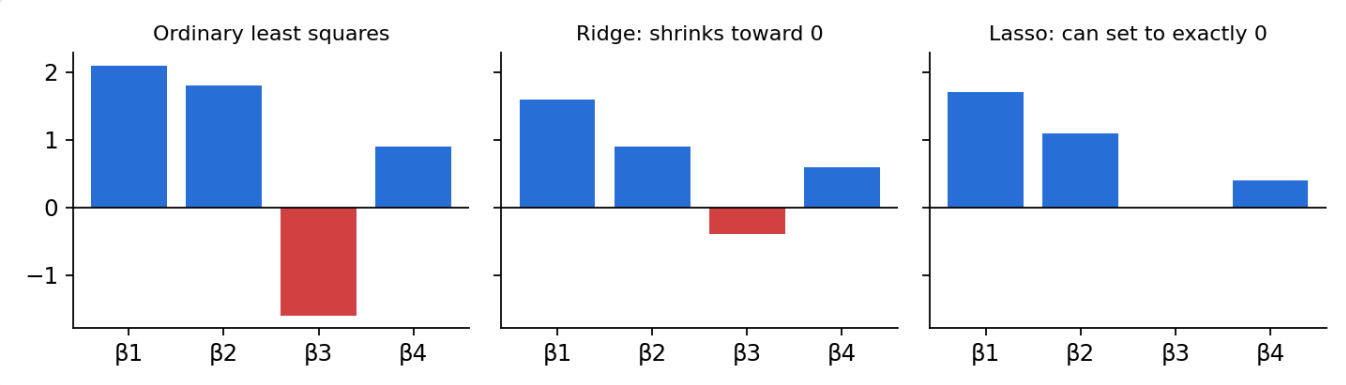
$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \ldots + \beta_p X_p + \varepsilon$$

Fit කළාට පස්සේ prediction එක $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X_1 + \hat{\beta}_2 X_2 + \hat{\beta}_3 X_3 + \ldots$ (error term එක නැති වෙනවා).

12.3 Multicollinearity විසඳීම – Ridge සහ Lasso

X2 සහ X3 එකිනෙකට සම්බන්ධයි කියමු. දෙකම ඕන නැහැ – එකකින් Y පැහැදිලි කරන්න පුළුවන්.

- **Ridge regression (L2)** β අගයන් **හැකි තරම් කුඩා** කරන්න උත්සාහ කරනවා. සම්බන්ධිත coefficients වලින් එකක් (උදා: β_2) 0.01 වගේ **කුඩා අගයකට** අඩු කරනවා, එතකොට Y ට X2 ගේ දායකත්වය ගොඩක් පොඩි වෙනවා.
- **Lasso regression (L1)** coefficient එකක් **හරියටම බිංදුවට** (උදා: $\beta_2 = 0$) කරන්න පුළුවන්. එතකොට X2 model එකෙන් ඉවත් වෙනවා, multicollinearity නැති වෙනවා.

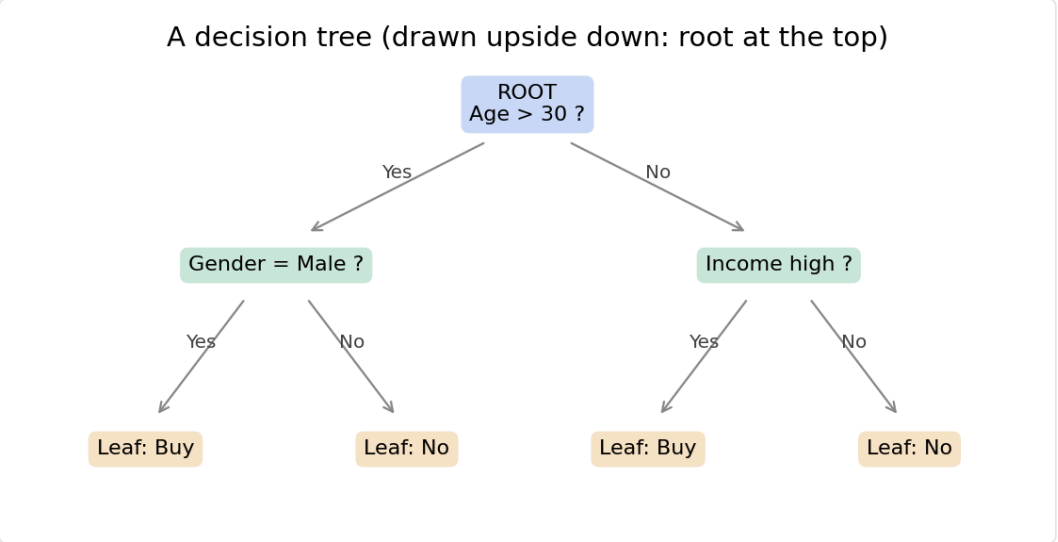


Ridge කුඩා කරනවා; Lasso variable එකක් සම්පූර්ණයෙන්ම ඉවත් කරන්න පුළුවන්

මේ ක්‍රමවලට **regularization techniques** කියනවා. **Regression සහ classification දෙකටම** භාවිතා කරන්න පුළුවන් – උදා: Ridge, linear regression එකටත් logistic regression එකටත් යොදන්න පුළුවන්.

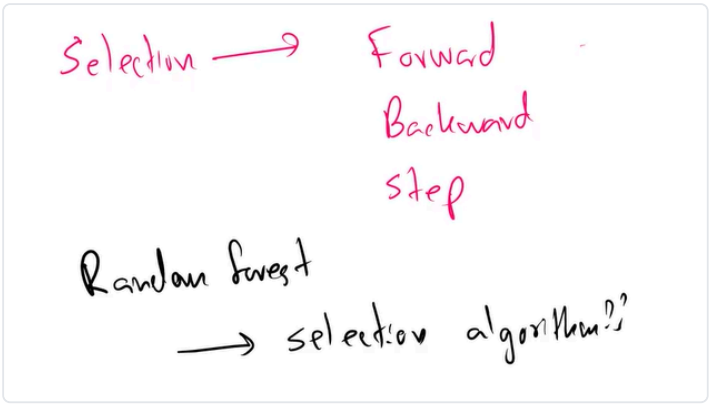
13. Decision trees සහ Random Forest

සාමාන්‍ය ගහක මුල් පහළින්. **Decision tree** එකක් අඳින්නේ **උඩු යටිකුරු කරලා**: **root (මුල)** උඩින්, ඒකෙන් **branches (අතු)** වලට බෙදෙනවා. හැම බෙදීමකදීම **criterion (කොන්දේසියක්)** තියෙනවා, උදා: "වයස > 30?" → වමට හෝ දකුණට; "Gender = male?" → වමට හෝ දකුණට. මේක **tree-based model** එකක්.



- ගස් ගොඩක් = **වනාන්තරයක් (forest)**.
- Variables 100ක් (X1 … X100) තියෙනවා නම්, හැම combination එකක්ම එක්ක ගස් අඳින්නේ නැහැ. හැම ගහකදීම / බෙදීමකදීම variables කිහිපයක් **අහඹු ලෙස (randomly) තෝරනවා**. ඒ නිසා **random forest** කියනවා.
- Random forest **regression සහ classification** දෙකටම භාවිතා කරන්න පුළුවන්.

14. Variable selection (විචල්‍ය තෝරාගැනීම)

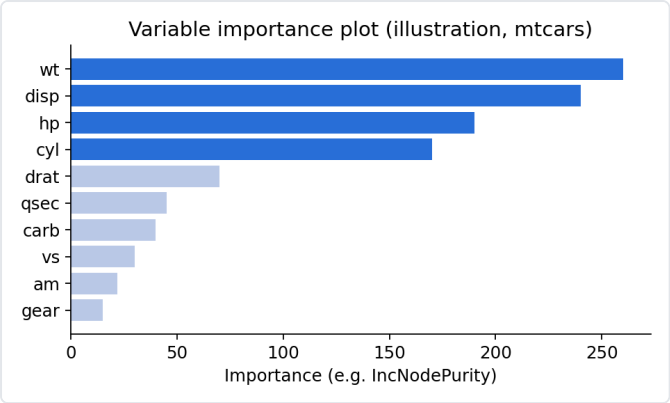


14.1 Multiple linear regression වල

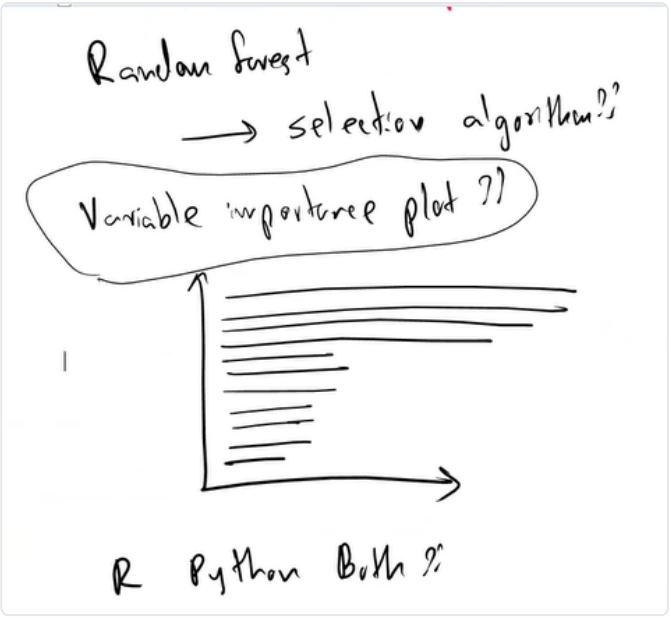
- **Forward selection** – variables නැතුව (null model) පටන් අරන් වඩාත්ම ප්‍රයෝජනවත් variable එක එකින් එක එකතු කරනවා.
- **Backward elimination** – හැම variable එකක්ම එක්ක (full model) පටන් අරන් අඩුම ප්‍රයෝජනවත් එක එකින් එක ඉවත් කරනවා.
- **Stepwise** – දෙකේම මිශ්‍රණයක්: හැම පියවරකදීම එකතු කරන්නත් ඉවත් කරන්නත් පුළුවන්.

14.2 Random forest වල – variable importance plot

Random forest එකෙන් **variable importance plot** එකක් ලැබෙනවා. හැම variable එකකටම තිරස් bar එකක් තියෙනවා: **දිග bar = වැදගත්**, **කෙටි bar = වැදගත් නැහැ**. හැම variable එකක්ම model එකට දාන්නේ නැහැ – වැදගත් ඒවා තෝරගන්නවා.



උදාහරණය

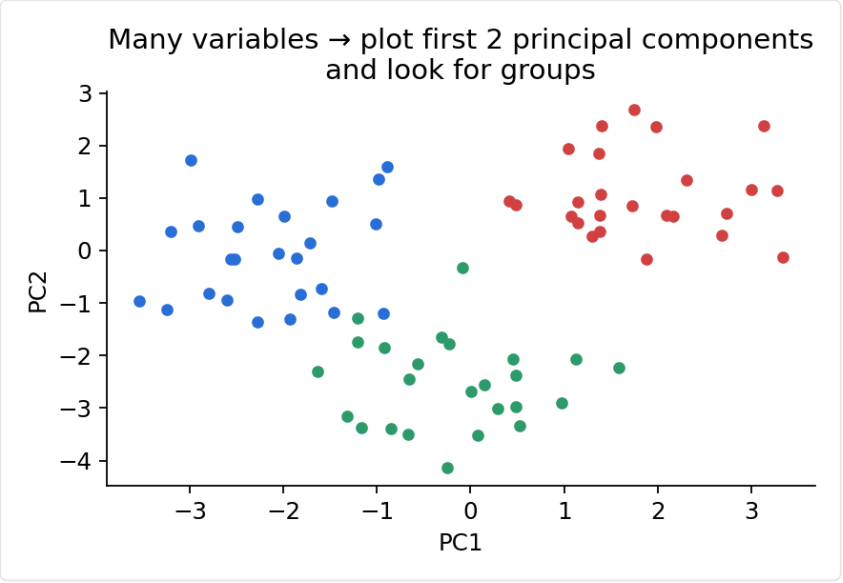


Whiteboard

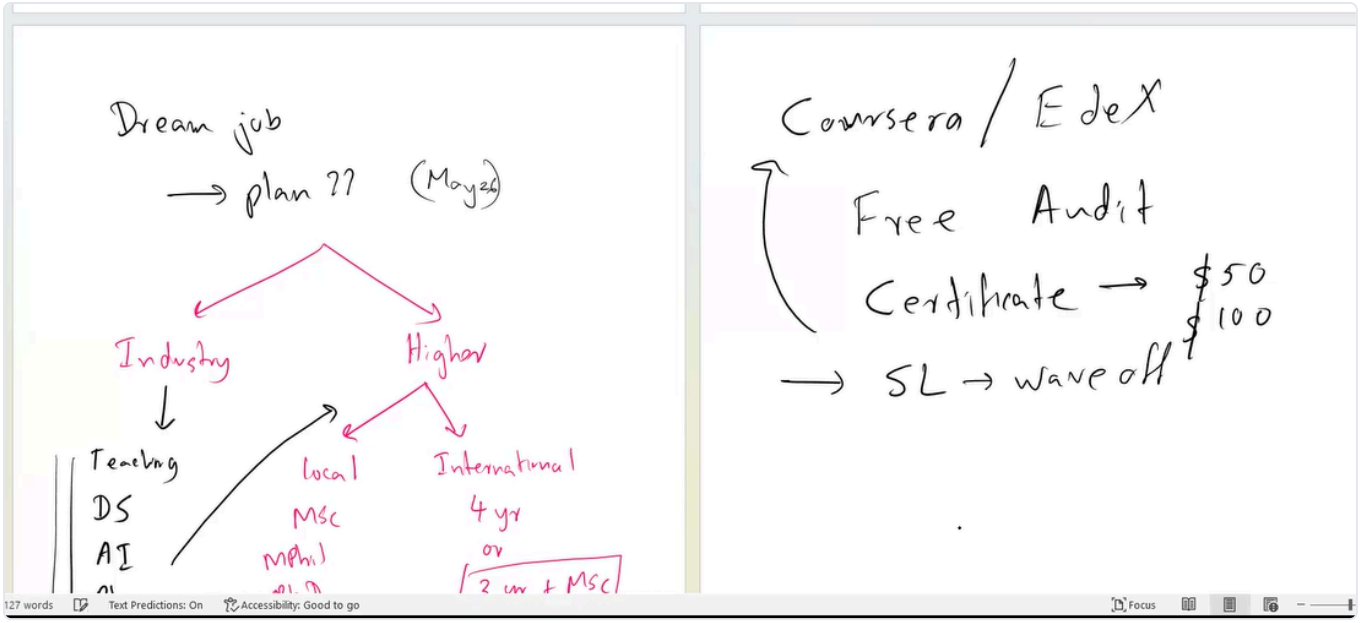
R වල: `randomForest(..., importance = TRUE)` ඊට පස්සේ `varImpPlot(model)`.

15. Dimension reduction – PCA

Variables ගොඩක් තියෙනකොට (ජීව විද්‍යාත්මක යෙදුම් වල බහුලයි) ඒ ඔක්කොම visualize කරන්න බැහැ. **Principal Component Analysis (PCA)** මගින් තොරතුරු වැඩි ප්‍රමාණයක් රඳවාගන්නා **principal components** කියන අලුත් variables හදනවා. ඊට පස්සේ **පළමු principal components දෙක** plot කරලා කණ්ඩායම් තියෙනවද බලනවා. PCA කියන්නේ **dimension reduction technique** එකක් (unsupervised).



16. කථිකාචාර්යතුමාගේ career උපදෙස්



Whiteboard: උපාධියෙන් පස්සේ සැලැස්ම

මේ පන්තිය අවුරුදු 3 general degree (Applied Science) කණ්ඩායමක්, සිසුන් 300ක් පමණ, ඉන් 60ක් පමණ statistics කරනවා. Lecturer ඔයාලගේ සිහින රැකියාව ගැන ඇහුවා (උත්තර: teaching, උසස් අධ්‍යාපනය, chemistry, AI engineer, ...), පහත උපදෙස් දුන්නා.

උපාධියෙන් පස්සේ මාර්ග දෙකක් (2026 මැයි පමණ)

- **Industry (රැකියා ක්ෂේත්‍රය)** – teaching, data science, AI, physics, chemistry, computer science රැකියා, ආදිය.
- **උසස් අධ්‍යාපනය (Higher studies)**
  - **දේශීය:** MSc, MPhil, PhD – ඔයාලා සුදුසුකම් ලබලා, නමුත් තරඟයක් තියෙනවා.
  - **විදේශීය:** සාමාන්‍යයෙන් **අවුරුදු 4 degree** එකක්, හෝ **අවුරුදු 3 degree + MSc** ඕන.
- සමහරු අවුරුදු කිහිපයක් වැඩ කරලා උසස් අධ්‍යාපනයට යනවා; සමහරු කලින් ඉගෙනගෙන පස්සේ industry එකට එනවා.

අනිත් උපාධිධාරීන්ගෙන් කැපී පෙනෙන්නේ කොහොමද

ඔයාලා තරඟ කරන්නේ batch එකේ 300 දෙනා එක්ක සහ කොළඹ, පේරාදෙණිය, ජයවර්ධනපුර ආදී වෙනත් විශ්වවිද්‍යාලවල 3 අවුරුදු general උපාධිධාරීන් එක්ක. හැමෝගෙම CV එක එක වගේ පේන නිසා ඔයාලා ඔයාලව "විකුණන්න (sell yourself)" ඕන:

1. ඉහළම විශ්වවිද්‍යාල (Stanford, MIT, Harvard) දෙන **Coursera / edX** online courses. **නොමිලේ audit කරන්න** පුළුවන්. Certificate එකට ඩොලර් 50–100 පමණ. Course එක සහ assignments ඉවර කරලා, **organizers ලට ආචාරශීලීව email එකක් යවලා**, ඔයා ශ්‍රී ලංකාවෙන් (සංවර්ධනය වෙමින් පවතින රටකින්) බව පැහැදිලි කරලා **fee එක waive කරන්න (කපා හරින්න)** ඉල්ලන්න. Certificate එක ලැබුණත් නැතත් course එක CV එකට දාන්න.
2. **Professional photo** එකක් එක්ක (social media photo එකක් නෙවෙයි) **LinkedIn** page එකක් හදන්න. කැමති සමාගම් follow කරලා network එක හදාගන්න – vacancy එකක් ආවාම එයාලා ඔයාව දකින්න පුළුවන්.

3. **Update කරපු CV** එකක් තියාගන්න. හැමෝම පාවිච්චි කරන Canva template එකම පාවිච්චි කරන්න එපා.
4. **GitHub** page එකක් හදලා ඔයාගේ projects සහ code upload කරන්න, එතකොට සේවා යෝජකයන්ට බලන්න පුළුවන්.
5. ඔයා ලියන විදිහ සේවා යෝජකයන්ට බලන්න **Medium** එකේ blogs ලියන්න.

17. R practical – mtcars උදාහරණය

පන්තියේ දුන්න කාර්යයන්: (1) `mtcars` data set එක load කරන්න; (2) variables කීයද? (3) records කීයද? (4) missing values තියෙනවද? (5) outliers තියෙනවද? (6) **mpg** (miles per gallon – ඉන්ධන කාර්යක්ෂමතාව) predict කරන්න සුදුසු model එකක් fit කරන්න, data **80:20** train/test වලට බෙදන්න seed එක **123** භාවිතා කරන්න.

> **Lecturer ගේ උපදෙස**
> මේ code එක ලියන්න AI tools වලින් අහන්න එපා. ඔයාම code ලියන්න උත්සාහ කරන්න – exams සහ assignments වලදී ඔයාටම ලියන්න වෙනවා.

පියවර 1 – Data load කිරීම

```
# STA 3402 – Day 1
# 1. load the mtcars dataset
data(mtcars)
```

`mtcars` කියන්නේ කාර් 32ක් ගැන R එකේම තියෙන (built-in) data set එකක් (1974 සඟරාවකින්). Help page එක කියවන්න `?mtcars` type කරන්න. ප්‍රධාන variables: **mpg** (ඉන්ධන කාර්යක්ෂමතාව), cyl (cylinders ගණන), disp (engine ප්‍රමාණය), hp (horsepower), drat, **wt** (බර, 1000 lbs), qsec (1/4 mile කාලය), vs, am (gear වර්ගය), gear, carb.

පියවර 2 සහ 3 – Variables සහ records ගණන

```
# 2. how many variables are there?
dim(mtcars)     # පේළි සහ columns දෙනවා: 32 11
ncol(mtcars)    # columns (variables) ගණන = 11

# 3. how many records are there?
nrow(mtcars)    # පේළි (records) ගණන = 32
```

උත්තරය: **variables 11** සහ **records 32**.

පියවර 4 – Missing values

```
A = c(10,15,20,25,34)
A
is.na(A)          # FALSE FALSE FALSE FALSE FALSE  (missing නැහැ)

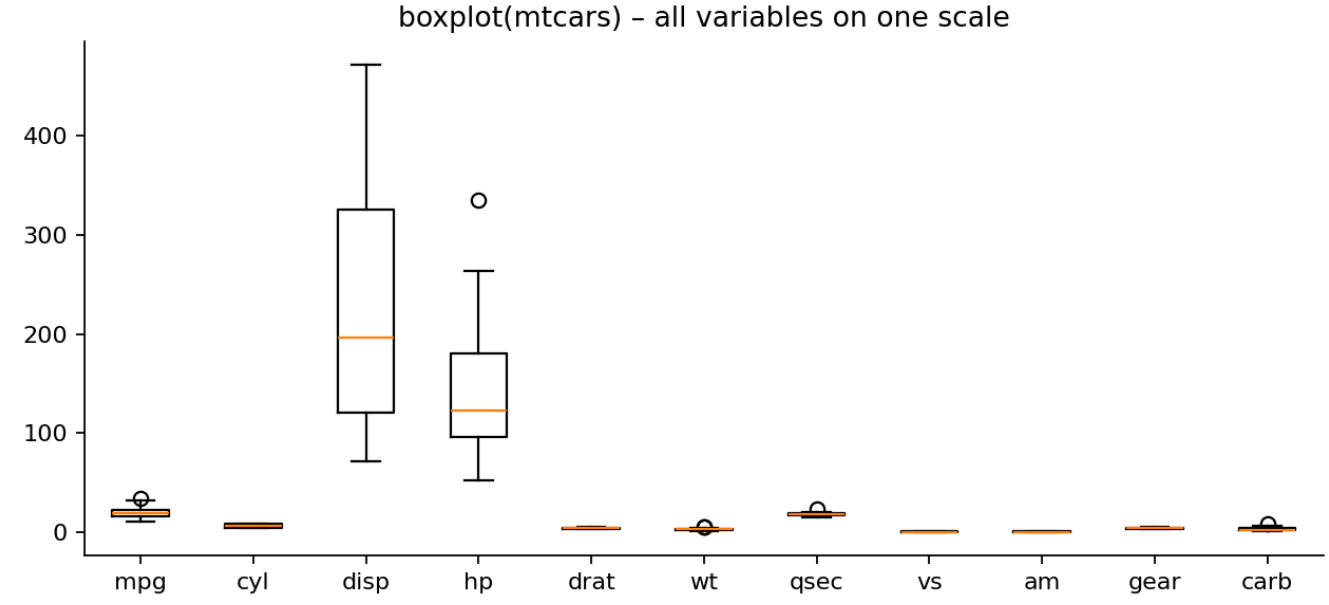
B = c(10,15,NA,34,85)
B
is.na(B)          # FALSE FALSE TRUE FALSE FALSE
sum(is.na(B))     # 1  (TRUE = 1 නිසා missing ගණන ලැබෙනවා)

summary(mtcars)   # හැම variable එකකම summary; missing තිබුණොත් NA's පෙන්නනවා
sum(is.na(mtcars))# 0  -> mtcars වල missing values නැහැ
```

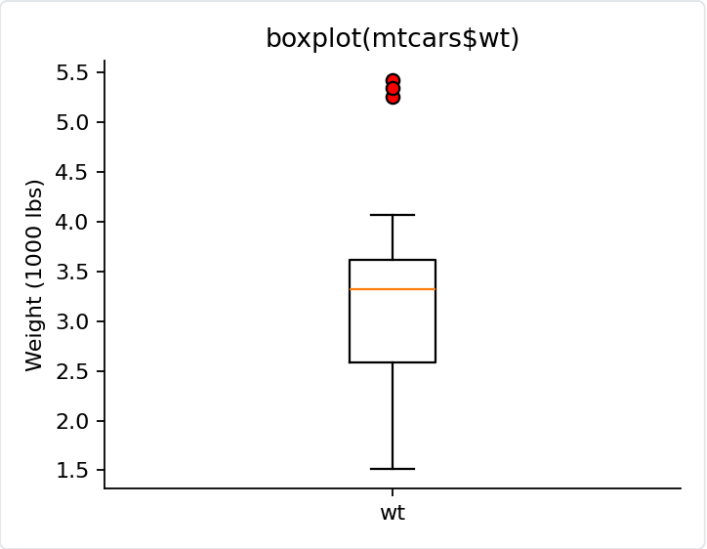
ක්‍රියා කරන විදිහ: `is.na()` හැම missing value එකකටම TRUE දෙනවා. `sum()` TRUE ගණන ගණන් කරනවා. පන්තියේ කියපු වෙනත් විකල්ප: `anyNA(mtcars)` (කොහේ හරි missing තියෙනවද – TRUE/FALSE) සහ `any(is.na(mtcars))`. මේ ඔක්කොම base R වල තියෙන නිසා package එකක් ඕන නැහැ. උත්තරය: **missing values නැහැ**.

පියවර 5 – Outliers

```
# 5. are there any outliers?
boxplot(mtcars)              # හැම variable එකකටම box plot
boxplot.stats(mtcars$mpg)    # $out හිස් -> mpg වල outliers නැහැ
boxplot.stats(mtcars$wt)     # $out = 5.424 5.345 -> outliers දෙකක්
boxplot(mtcars$wt)
```



boxplot(mtcars) – disp සහ hp ගොඩක් ලොකු පරිමාණයක තියෙන නිසා අනිත් boxes පැතලි වගේ පේනවා (scale කරන්න තවත් හේතුවක්)



wt වල outliers දෙකක් (5.424 සහ 5.345)

`boxplot.stats()` box plot එකේ අංක දෙනවා. wt සඳහා `$stats`: 1.513, 2.5425, 3.325, 3.65, 5.25 (පහළ whisker, පහළ hinge, median, ඉහළ hinge, ඉහළ whisker). `$out` එකේ outliers තියෙනවා. mpg සඳහා `$out` = `numeric(0)`, ඒ කියන්නේ **outliers නැහැ**. හැම variable එකක්ම මේ විදිහට check කරන්න ඕන.

පියවර 6 – Seed එකක් එක්ක train / test split

```
# 6. fit a suitable prediction model to predict mpg
# use 123 as the seed to split 80:20 train and test sets
set.seed(123)
trainID = sample(1:nrow(mtcars), 0.8*nrow(mtcars), replace = FALSE)
trainSet = mtcars[trainID,]
head(trainSet)

testID = mtcars[-trainID,]    # මේක ඇත්තටම TEST SET එක
head(testID)
```

පේළියෙන් පේළිය:

- `1:nrow(mtcars)` = පේළි අංක 1 සිට 32 දක්වා. 32 කියලා type කරනවා වෙනුවට `nrow()` පාවිච්චි කරන එකෙන් code එක පොදු (general) වෙනවා. (පන්තියේදී lecturer මුලින් වැරදිලා `ncol` type කළා – එය **nrow** (පේළි ගණන) විය යුතු බව ශිෂ්‍යයෙක් පෙන්නුවා.)
- `0.8*nrow(mtcars)` = 25.6 → R training වලට **පේළි 25ක්** ගන්නවා; ඉතිරි **පේළි 7** test set එක.
- `replace = FALSE` – එකම පේළිය දෙපාරක් තෝරන්නේ නැහැ.
- `mtcars[trainID, ]` – data frame එකක් index කරන්නේ `[row, column]` විදිහට. තෝරපු පේළි අංක දීලා column කොටස හිස්ව තිබ්බාම **හැම column එකක්ම** ගන්නවා.
- `mtcars[-trainID, ]` – minus ලකුණෙන් "මේ පේළි **හැර** අනිත් ඔක්කොම" → test set එක.
- `head()` ඉක්මනින් බලන්න පළමු පේළි 6 පෙන්නනවා.

set.seed() ඕන ඇයි?

`sample()` පේළි අහඹු ලෙස තෝරන නිසා run කරන හැම පාරම වෙනස් train/test sets ලැබෙනවා. අද report එකෙන් භාගයක් ලියලා හෙට ආයේ code එක run කළොත් results වෙනස් වෙලා report එක ආයේ ලියන්න වෙනවා.
මිනිසෙක් වගේ computer එකකට අහඹු අංකයක් "හිතන්න" බැහැ (අහපුවාම ශිෂ්‍යාවක් "5" කිව්වා). ඒක input එකක් අරන් අංක හදන **algorithm** එකක් පාවිච්චි කරනවා – මේවා **pseudo-random numbers (ව්‍යාජ අහඹු අංක)**. Seed එකක් නොදුන්නොත් R input එක විදිහට **ඔරලෝසු වේලාව (clock time)** ගන්නවා, ඒ නිසා හැම පාරම results වෙනස්. Seed එක (123) දුන්නොත් input එක ස්ථිරයි, ඒ නිසා **හැම පාරම එකම sample එක** → results **නැවත ලබාගන්න (reproduce)** පුළුවන්.

පියවර 7 – Multiple linear regression fit කිරීම

```
?mtcars
# mpg is a continuous variable -> regression problem

# multiple linear regression
mlrOutput = lm(trainSet$mpg ~ ., data = trainSet)
# dot means use all the variables
summary(mlrOutput)
```

- `lm()` = linear model. `~` ට වමින් response එක, දකුණු පැත්තේ predictors. **තිත (.)** කියන්නේ "data එකේ අනිත් හැම variable එකක්ම".
- `summary()` intercept එක, හැම coefficient ($\hat{\beta}$) එකක්ම, p-value, R^2 ආදිය පෙන්නනවා. පන්තියේදී full model එකේ intercept එක 21 පමණ, **cyl ට negative coefficient** එකක්, එක variable එකක් විතරයි significant – ඒකත් **10%** මට්ටමින් විතරයි. ඒ නිසා **variable selection** ඕන.

ප්‍රයෝජනවත් tip එකක් (වැදගත්!)

Formula එක `lm(trainSet$mpg ~ ., data = trainSet)` වෙනුවට `lm(mpg ~ ., data = trainSet)` විදිහට ලියන්න. `trainSet$mpg ~ .` විදිහට ලිව්වොත් වම් පැත්ත "mpg" column එක බව R හඳුනාගන්නේ නැහැ, ඒ නිසා තිතට **mpg ම predictor එකක් විදිහට** ඇතුළත් වෙන්න පුළුවන් – "perfect fit" warning එකක් එක්ක තේරුමක් නැති results ලැබෙනවා. Column නම විතරක් ලිව්වාම මේ ප්‍රශ්නය නැහැ. පහළ `nullModel`, `fullModel` වලටත් මේක අදාළයි.

පියවර 8 – step() එකෙන් variable selection

```
# null model (intercept එක විතරයි)
nullModel = lm(trainSet$mpg ~ 1, data=trainSet)
## step(nullModel, direction = "forward", scope=c(list all the variables), data=trainSet)

# full model (හැම variable එකක්ම)
fullModel = lm(trainSet$mpg ~ ., data = trainSet)
step(fullModel, direction = "backward", data=trainSet)

selModel = step(fullModel, direction = "backward", data=trainSet)
summary(selModel)
```

- **Null model** (`~ 1`) = intercept එක විතරයි, predictors නැහැ. **Forward** selection පටන් ගන්න තැන. එකතු කරන්න පුළුවන් variables ලැයිස්තුව `scope` එකෙන් දෙන්න ඕන, උදා: `scope = formula(fullModel)`.
- **Full model** = හැම variable එකක්ම. **Backward** elimination පටන් ගන්න තැන.
- `step()` **AIC** පාවිච්චි කරනවා (අඩු නම් හොඳයි). හැම iteration එකකදීම ඉවත් කළාම AIC වැඩිපුරම අඩු වෙන variable එක ඉවත් කරනවා, තවත් ඉවත් කිරීමකින් වාසියක් නැති වුණාම නවතිනවා. පන්තියේදී අවසාන model එකේ ඉතිරි වුණේ **cyl, wt සහ qsec**.
- `summary(selModel)` එකෙන් පෙනුණා මේවායින් සමහරක් significant නැහැ, පැහැදිලිවම significant වුණේ **wt**. ඒ නිසා lecturer **wt විතරක්** එක්ක අවසාන model එක fit කළා:

```
mFinal = lm(mpg ~ wt, data = trainSet)
summary(mFinal)
```

තේරුම: mpg ප්‍රධාන වශයෙන් රඳා පවතින්නේ කාර් එකේ **බර** මත – බර වැඩි කාර් වලට **ගැලුමකට සැතපුම් අඩුයි** (negative slope).

පියවර 9 – Random forest

```
library(randomForest)          # පළමු වතාවට install.packages("randomForest")
set.seed(123)
rf_model = randomForest(mpg ~ ., data = trainSet)
rf_model
```

`rf_model` print කළාම වර්ගය (regression), ගස් ගණන (default 500), හැම split එකකදීම උත්සාහ කරන variables ගණන, mean of squared residuals සහ "% Var explained" (R^2 වගේ) පෙන්නනවා. Variable importance plot එක බලන්න `importance = TRUE` එකතු කරලා `varImpPlot(rf_model)` පාවිච්චි කරන්න.

පියවර 10 – Test set එකෙන් model එක පරීක්ෂා කිරීම (workflow එක සම්පූර්ණ කරන්න)

```
pred_lm = predict(mFinal, newdata = testID)
mean((testID$mpg - pred_lm)^2)      # linear model එකේ test MSE

pred_rf = predict(rf_model, newdata = testID)
mean((testID$mpg - pred_rf)^2)      # random forest එකේ test MSE
```

Test MSE අඩු model එක අලුත් data වලට වඩා හොඳින් predict කරනවා.

> **ඊළඟට කරන්න (code එකේ තියෙනවා)**
> XGBoost, Support Vector Regression (SVR) සහ regularization (Ridge/Lasso). Lecture එක මෙතනින් නැවතුණා; ඊළඟ session එකේ මේවා කරනවා.

18. Assignment 1 – Kaggle competition

කරුණ	විස්තරය
අවසාන දිනය	සතියයි – **ලබන සඳුදා ප.ව. 5.00 ට කලින්**
Data	**මත්ද්‍රව්‍ය භාවිතයට සම්බන්ධ රෝගීන්ගේ මානසික සෞඛ්‍ය තත්ත්වය** ගැන අභියෝගාත්මක data set එකක්
කාර්යය	**Drug category** එක predict කරන model එකක් හදන්න → **classification** ගැටලුවක්
Platform	**Kaggle competition** එකක් විදිහට සකසලා (link එක Google Drive / WhatsApp එකේ)

කරන විදිහ

1. Kaggle account එකක් නැත්නම් Gmail එකෙන් හදාගන්න. **Screen name එක ඔයාගේ ඇත්ත නම** (මුල් නම, අන්තිම නම) වෙන්න ඕන, හඳුනාගන්න පුළුවන් වෙන්න.
2. Log in වෙලා දීපු link එක open කරලා **"Join Competition"** click කරන්න.
3. Data tab එකේ තියෙනවා: **train** data set, **test** data set, **sample submission** file එක සහ **variable description** එක.
4. **Training** set එකේ response variable (drug category) තියෙනවා. **Test** set එකේ **නැහැ**.
5. Training data මත classification model එක fit කරලා test data වලට drug category predict කරන්න.
6. Predictions **sample submission file එකේ format එකටම** දාන්න (ඒක download කරලා දෙවන column එකට predictions paste කරන්න පුළුවන්).
7. **Submit Predictions** click කරන්න. ඔයාගේ score එක (accuracy) ඔයාගේ නම එක්ක **leaderboard** එකේ, යාළුවෝ එක්ක rank වෙලා පේනවා.
8. **දවසකට submissions 5ක්** කරන්න පුළුවන් (රෑ 12ට reset වෙනවා) – සතියකට 35ක් පමණ. Score එක වැඩි කරගන්න උත්සාහ කරන්න!

Report එක (PDF)

- PDF එකක් upload කරන්න (LMS access ලැබෙනකම් Google Form upload link එකක් දෙනවා).
- තිබිය යුතු දේ: **data pre-processing පියවර**; කරපු **exploratory data analysis**; **model building පියවර** පැහැදිලිව සහ සම්පූර්ණයෙන්; ඔයාගේ **final model** එක පැහැදිලි, හොඳින් සංවිධිත ආකාරයට.
- නැති හෝ අසම්පූර්ණ පියවර වලට ලකුණු අඩු කරනවා – final model එක විතරක් දුන්නාම මදි.
- Format: **පිටු 8කට නොවැඩි**, **Times New Roman, size 12**, **1.5 line spacing**.
- ඔයාගේ හොඳම Kaggle model එක report කරන final model එක වෙනවා.

19. සාරාංශය සහ පුනරීක්ෂණ ප්‍රශ්න

ප්‍රධාන කරුණු

- DL ⊂ ML ⊂ AI. ML = supervised (Y තියෙනවා) + unsupervised (Y නැහැ).
- Y අංකයක් → regression; Y category එකක් → classification.
- Workflow: load → pre-process (duplicates, dummy coding, missing, outliers, scaling) → EDA → split → model → test (MSE).
- Missing values: ඉවත් කරන්න හෝ impute කරන්න (mean / median / mode).
- Outliers: IQR නීතිය, Q1 − 1.5·IQR සහ Q3 + 1.5·IQR.
- Normal නම් standardize; නැත්නම් normalize (min-max).
- Multicollinearity → Ridge (කුඩා කරනවා) හෝ Lasso (0 කරනවා) = regularization.
- Variable selection: forward, backward, stepwise; RF → variable importance plot.
- Results නැවත ලබාගන්න හැමවිටම `set.seed()` දාන්න.

ඔයාම පරීක්ෂා කරන්න

1. Supervised සහ unsupervised learning වලට එක උදාහරණය බැගින් දෙන්න.
2. Pass/fail predict කිරීමත් supervised learning වෙන්නේ ඇයි?
3. Cold start problem කියන්නේ මොකක්ද? උදාහරණයක් දෙන්න.
4. Marks: 40, 70, NA, 55. Mean-imputed අගය සොයන්න. (උත්තරය: 55)
5. Q1 = 20, Q3 = 30. Outlier fences සොයන්න. (උත්තරය: 5 සහ 45)
6. Standardize කරන්නේ කවදද, normalize කරන්නේ කවදද?
7. ගෙවල් මිල predict කරන්න logistic regression පාවිච්චි කරන්න බැරි ඇයි?
8. Multicollinearity කියන්නේ මොකක්ද? Ridge සහ Lasso ඒක විසඳන්නේ වෙනස් විදිහට කොහොමද?
9. Random forest එකකට "random" කියන්නේ ඇයි?
10. `set.seed(123)` කරන්නේ මොකක්ද, ඒක ඕන ඇයි?
11. R වල `lm(mpg ~ ., data = trainSet)` එකේ තිතෙන් අදහස් කරන්නේ මොකක්ද?
12. `mtcars[-trainID, ]` මොකක්ද return කරන්නේ?