STA 3402 – Machine Learning & Neural Networks

Lecture 3 – Categorical සහ Mixed Data සඳහා Dimension Reduction: MCA සහ FAMD

(Cluster Analysis හැඳින්වීමත් සමඟ)

Lecture R code එක, Tutorial 1 (MCA), Self-Learning Activity එක සහ data sets දෙක භාවිතා කර සකස් කළ සම්පූර්ණ සටහන් (සරල සිංහලෙන්).
මේ සටහන් වල ඇති සියලුම අංක සහ plots ඔයාගේ data files මත R code එක ඇත්තටම run කරලා ලබාගත්ත ඒවා (FactoMineR 2.9, factoextra 1.0.7).

> **මේ සටහන කියවන විදිහ**
> තාක්ෂණික වචන (technical terms) exam එකේදී සහ R code එකේදී ඉංග්‍රීසියෙන්ම එන නිසා ඒවා ඉංග්‍රීසියෙන්ම තියලා තේරුම සිංහලෙන් දීලා තියෙනවා. රූපවල සහ R output වල labels ඉංග්‍රීසියෙන් තියෙන්නේ ඒ නිසා.

පටුන

1. Categorical data සඳහා PCA ප්‍රමාණවත් නොවන්නේ ඇයි
2. ක්‍රමයක් තෝරා ගැනීම: PCA, CA, MCA, FAMD, MFA
3. MCA – අදහස
4. Tutorial 1: MCA පියවරෙන් පියවර (student_learning_profiles_categorical.csv)
5. FAMD – අදහස
6. FAMD පියවරෙන් පියවර (graduate_employability_mixed.csv)
7. අඩු කළ coordinates clustering සඳහා භාවිතා කිරීම
8. Self-Learning Activity – සම්පූර්ණ උත්තර (Parts A, B, C, D සහ optional challenge)
9. Cluster analysis හැඳින්වීම (hierarchical clustering)
10. සාරාංශය සහ සම්පූර්ණ R workflow එක

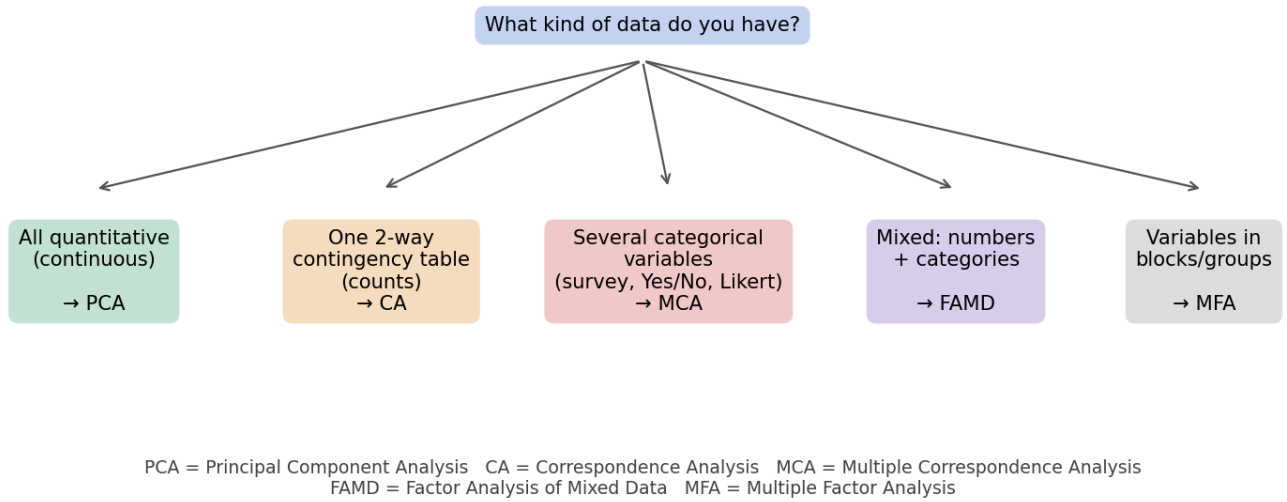
1. Categorical data සඳහා PCA ප්‍රමාණවත් නොවන්නේ ඇයි

පසුගිය සතියේ අපි **PCA** ඉගෙන ගත්තා. PCA වැඩ කරන්නේ **quantitative (සංඛ්‍යාත්මක)** variables වලට විතරයි, සාමාන්‍ය (Euclidean) දුර භාවිතා කරනවා. පසුගිය lecture එකේ අන්තිමට ආපු ප්‍රශ්නය: **variables ඔක්කොම (හෝ සමහරක්) categorical නම් මොකද කරන්නේ?**

- **Nominal** categories (උදා: Study_Mode = Solo / Group / Mixed) වලට **පිළිවෙළක් නැහැ, සංඛ්‍යාත්මක දුරකුත් නැහැ**. "Group = 1, Mixed = 2, Solo = 3" කියන්නේ තේරුමක් නැති අංක.
- Low / Medium / High වගේ **පිළිවෙළක් ඇති** categories වුණත් 1, 2, 3 විදිහට ආදේශ කළොත් **සමාන පරතර බලෙන් දානවා** (Low→Medium = Medium→High) සහ ඒවා නිවැරදි මිනුම් වගේ සලකනවා. මේකෙන් අපි මැනපු නැති **දුරේ තේරුම වෙනස් වෙනවා**.

- ඒ නිසා categories සඳහාම හදපු ක්‍රම ඕන: **MCA** (ඔක්කොම categorical) සහ **FAMD** (mixed: numeric + categorical).

2. ක්‍රමයක් තෝරා ගැනීම



ක්‍රමය	භාවිතා කරන්නේ...	R function (FactoMineR)
PCA	ඔක්කොම variables quantitative (continuous) නම්	`PCA()` හෝ `prcomp()`
CA – Correspondence Analysis	Categorical variables දෙකක එක contingency table එකක් (counts), උදා: දිස්ත්‍රික්කය × ප්‍රවාහන ක්‍රමය	`CA()`
MCA – Multiple Correspondence Analysis	Categorical variables කිහිපයක් (surveys, Yes/No, Likert)	`MCA()`
FAMD – Factor Analysis of Mixed Data	Quantitative සහ categorical variables මිශ්‍රණයක්	`FAMD()`
MFA – Multiple Factor Analysis	Variables **කණ්ඩායම්/blocks** වලට සංවිධානය වෙලා (උදා: genetics, clinical, imaging, lifestyle)	`MFA()`

Packages: `install.packages(c("FactoMineR", "factoextra"))`. **FactoMineR** analysis එක කරනවා; **factoextra** ලස්සන ggplot2 graphs හදනවා (`fviz_` වලින් පටන් ගන්න functions).

3. MCA – අදහස

සංකල්පීය වශයෙන් MCA දේවල් තුනක් කරනවා:

1. හැම category එකකටම 0/1 column එකක් ඇති **indicator (disjunctive) table** එකක් හදනවා.
2. **Category profiles** සසඳනවා (කවුද මොන categories තෝරගත්තේ).

3. ශිෂ්‍යයෝ **සාමාන්‍ය profile එකෙන් අපගමනය වන** විදිහ සාරාංශ කරන **dimensions** කිහිපයක් හොයනවා.

3.1 Indicator (disjunctive) table එක – උදාහරණය

අපේ data වලින් ශිෂ්‍යයෝ පස් දෙනෙක්, variables දෙකක් එක්ක:

ශිෂ්‍යයා	Study_Mode	Attendance
S001	Solo	Regular
S003	Group	Regular
S007	Solo	Occasional
S009	Mixed	Occasional
S021	Solo	Rare

	Group	Mixed	Solo	Occ.	Rare	Reg.
S001	0	0	1	0	0	1
S003	1	0	0	0	0	1
S007	0	0	1	1	0	0
S009	0	1	0	1	0	0
S021	0	0	1	0	1	0

හැම පේළියකම variable එකකට හරියටම එක "1" ක් තියෙනවා. R වල මේක `FactoMineR::tab.disjonctif(data)` එකෙන් බලන්න පුළුවන්. MCA කියන්නේ මූලිකවම **මේ 0/1 table එකේ Correspondence Analysis** එකක්.

- **ශිෂ්‍යයෙක්** නිරූපණය වෙන්නේ ඔහු/ඇය සතු categories කට්ටලයෙන්.
- **සමාන ශිෂ්‍යයන්** තෝරන categories map එකේ **සමාන දිශාවලට** යනවා.
- **දුර්ලභ (rare) categories** "අසාමාන්‍යයි", ඒ නිසා ඒවා **origin එකෙන් ඈතින්** තියෙනවා, ලොකු බලපෑමක් කරන්න පුළුවන්.

3.2 MCA වල භාවිතා වන වචන

වචනය	තේරුම
Inertia	Categorical data වල "විචලනය" (PCA වල variance වගේ). මුළු inertia = (K/J) − 1, මෙහි K = categories ගණන, J = variables ගණන.
Eigenvalue	Dimension එකකින් පැහැදිලි කරන inertia. MCA වල හැම eigenvalue එකක්ම ≤ 1. Dimensions ගණන = K − J.
Coordinate	Dimension එකක් මත category/ශිෂ්‍යයෙකුගේ පිහිටීම.
Contribution (contrib)	Category එකක් dimension එකක් **හදන්න** කොච්චර (%) උදව් වෙනවද. එක dimension එකක ඔක්කොම contributions එකතුව 100%.
cos2 (squared cosine)	Category/ශිෂ්‍යයෙක් dimension එකක් හෝ plane එකක් මත කොච්චර **හොඳින් නිරූපණය** වෙනවද (0 සිට 1). 1 ට ළඟ = හොඳයි.
eta2 (η^2)	සම්පූර්ණ variable එකක් සඳහා: variable එක සහ dimension එක අතර squared correlation ratio (0 සිට 1).
v.test	z වගේ test අගයක්. |v.test| > 2 (දළ වශයෙන් 1.96) නම් ඒ dimension එකේ category එක 0 ට වඩා සැලකිය යුතු ලෙස වෙනස්.
Supplementary variable	පස්සේ map එකට **project** කරන, නමුත් axes හදන්න උදව් **නොකරන** variable එකක්.

අර්ථකථන අනතුරු ඇඟවීම (tutorial එකෙන්)

- **Origin එකට ළඟ** categories සාමාන්‍යයෙන් වෙන්කර හඳුනාගැනීමට උදව් නොවන (පොදු, "සාමාන්‍ය") ඒවා.
- **Origin එකෙන් ඈත** categories dimensions නිර්වචනය කරන්න උදව් වෙන්න පුළුවන්.
- **සමාන දිශාවක** ඇති categories සමාන response profiles පෙන්නන්න පුළුවන්.
- **Plot එකේ කෙටි දුරක් ශක්තිමත් සම්බන්ධයක් ස්වයංක්‍රීයව ඔප්පු කරන්නේ නැහැ.** Contribution, cos2, frequencies සහ විෂය දැනුම එකට භාවිතා කරන්න.

4. Tutorial 1: MCA පියවරෙන් පියවර

Data: `student_learning_profiles_categorical.csv` – ශිෂ්‍යයන් 180, columns 12: `Student_ID`, `Programme`, `Study_Mode`, `Resource_Preference`, `Attendance`, `Assignment_Timing`, `Coding_Confidence`, `Statistics_Confidence`, `AI_Assistant_Use`, `Preferred_Assessment`, `Primary_Device`, `Performance_Band`. ඔක්කොම categorical.

- **Active variables** (axes හදන්නේ මේවා): ඉගෙනුම් හැසිරීම / කැමැත්ත පිළිබඳ variables 9.
- **Supplementary variables** (project කරනවා විතරයි): `Programme` සහ `Performance_Band`.

4.1 Data කියවීම

```
dat <- read.csv("student_learning_profiles_categorical.csv",
                stringsAsFactors = TRUE)
str(dat)
head(dat)
```

- `stringsAsFactors = TRUE` හැම text column එකක්ම **factor** (categorical variable) එකක් බවට හරවනවා. MCA ට factors ඕන.
- `str(dat)`: obs. 180 ක්, variables 12 ක්, ඔක්කොම factors (උදා: Programme: levels 4; Attendance: levels 3).
- CSV එක working directory එකේ save කරන්න, නැත්නම් සම්පූර්ණ path එක දෙන්න / `setwd()` භාවිතා කරන්න.

Lecture code එකේ අමතර පේළියක්

`read.csv("data2.txt", sep=";")` පෙන්නන්නේ අගයන් comma වෙනුවට **semicolon (;)** වලින් වෙන් කළ file එකක් කියවන විදිහ. `sep` එකෙන් R ට separator එක කියනවා. (`read.csv2()` ත් default ලෙස ";" භාවිතා කරනවා.)

```
# identifier එක analysis එකෙන් ඉවත් කරන්න
rownames(dat) <- dat$Student_ID
dat$Student_ID <- NULL

# variable වර්ග check කරන්න
sapply(dat, class)
# කිසියම් categorical column එකක් තවමත් character නම් convert කරන්න
dat[] <- lapply(dat, as.factor)
```

- ID එක variable එකක් **නෙවෙයි** – ඒකෙන් හැම ශිෂ්‍යයෙක්ටම නමක් දෙනවා විතරයි. ඒක **row names** වලට ගෙනිහින් (plots වල ශිෂ්‍යයන් label කරන්න පුළුවන් වෙන්න) column එක මකනවා. නැත්නම් MCA IDs 180 categories 180 ක් විදිහට සලකයි!
- `sapply(dat, class)` හැම column එකකම class එක පෙන්නනවා → ඔක්කොම "factor".
- `dat[] <- lapply(dat, as.factor)` **හැම** column එකක්ම factor කරනවා. `[]` නිසා data frame එකක් විදිහටම තියෙනවා (නැත්නම් list එකක් ලැබෙනවා).

```
library(FactoMineR)
library(factoextra)
?MCA       # help page එක
?mca       # වැඩ කරන්නේ නැහැ – R case-sensitive; function එක MCA()
```

4.2 මුලින්ම category frequencies බලන්න

```
lapply(dat, table)
round(prop.table(table(dat$Attendance)) * 100, 1)
```

Dimension reduction මගින් මූලික exploratory analysis එකේ අවශ්‍යතාව **නැති වෙන්නේ නැහැ**. ඔයාගේ data වල ප්‍රතිඵල:

Variable	Categories (ගණන්, n = 180)
Programme *(sup.)*	Biological Science 31, Data Science 59, Physical Science 42, Statistics 48
Study_Mode	Group 47, Mixed 71, Solo 62
Resource_Preference	Interactive Tools 55, Lecture Notes 59, Videos 66
Attendance	Occasional 51, **Rare 12**, Regular 117
Assignment_Timing	Early 51, Last Minute 33, On Time 96
Coding_Confidence	High 74, Low 31, Medium 75
Statistics_Confidence	High 80, Low 32, Medium 68
AI_Assistant_Use	Frequent 96, **Never 16**, Occasional 68
Preferred_Assessment	Exam 57, Project 86, Quiz 37
Primary_Device	Laptop 125, Mobile 40, **Shared Computer 15**
Performance_Band *(sup.)*	High 83, Low 27, Medium 70

Attendance ප්‍රතිශත: Occasional 28.3%, Rare 6.7%, Regular 65.0%.

Checkpoint 1 – උත්තර

1. **Categories තුනක් ඇති:** ඔක්කොම active variables (Study_Mode, Resource_Preference, Attendance, Assignment_Timing, Coding_Confidence, Statistics_Confidence, AI_Assistant_Use, Preferred_Assessment, Primary_Device) සහ Performance_Band. Programme ට විතරයි හතරක්.
2. **දුර්ලභ categories:** Attendance = Rare (12, 6.7%), Shared Computer (15, 8.3%), AI = Never (16, 8.9%). දුර්ලභ categories වලට ලොකු coordinates ලැබෙන නිසා axis එකක් ආධිපත්‍යය ගන්න පුළුවන්; පරිස්සමෙන් අර්ථකථනය කරන්න.
3. **සමාන රටා (MCA ට කලින් අනුමානය):** Rare attendance, Last Minute submission, Low confidence සහ Mobile device එකට යන්න පුළුවන්; Regular attendance, Early submission, High confidence සහ Laptop එකට යන්න පුළුවන්.
4. **Low/Medium/High = 1/2/3:** මේකෙන් සමාන, මැනපු පරතර උපකල්පනය කරලා ordinal label එකක් අංකයක් බවට හරවනවා. එතකොට Euclidean දුර අත්තනෝමතික coding එකක් මත රඳා පවතින නිසා දුරේ තේරුම වෙනස් වෙනවා. MCA හැම category එකක්ම වෙන වෙනම සලකන නිසා එවැනි උපකල්පනයක් ඕන නැහැ.

4.3 MCA run කිරීම

```
sup_idx <- which(names(dat) %in% c("Programme", "Performance_Band"))
sup_idx          # 1 11  (column අංක)

res_mca <- MCA(
  dat,
  quali.sup = sup_idx,    # supplementary categorical variables
  ncp = 5,                # ප්‍රතිඵල වල dimensions 5ක් තියාගන්න
  graph = FALSE           # දැන් plots අඳින්න එපා (TRUE නම් default plots අඳිනවා)
)
res_mca
```

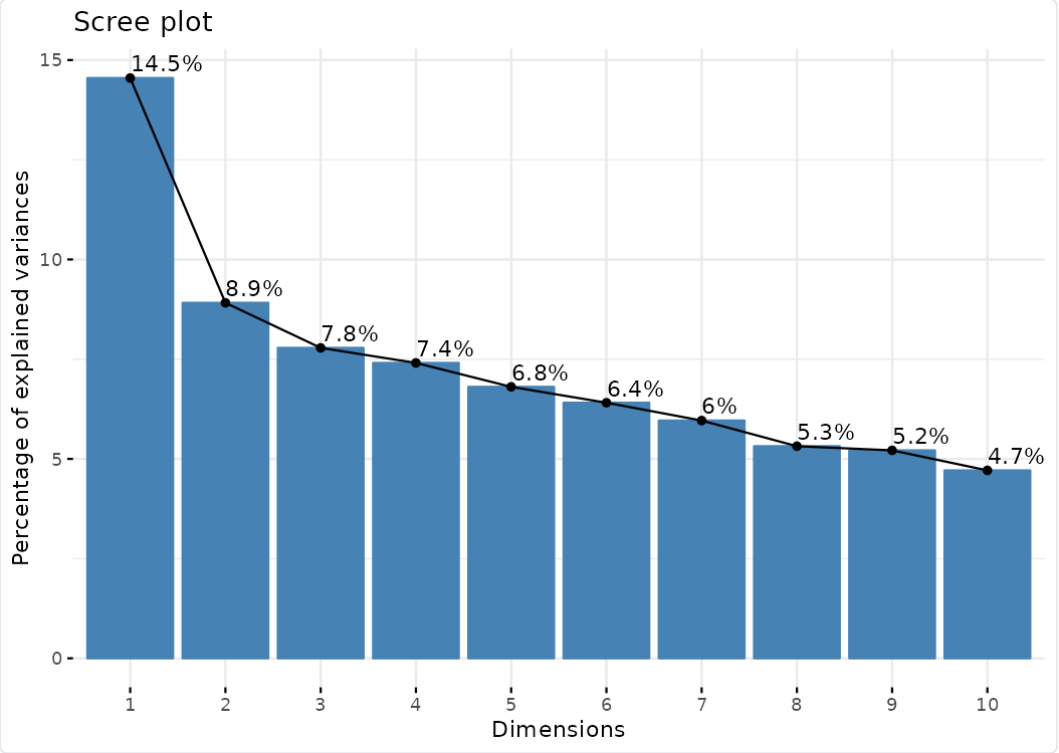
- `names(dat) %in% c(...)` හැම column නමකටම TRUE/FALSE දෙනවා; `which()` TRUE ඒවායේ ස්ථාන දෙනවා → 1 සහ 11.
- `quali.sup` = supplementary **qualitative** variables. ඒවා අවසාන map එකට project කරනවා, නමුත් axes තියෙන තැනට **බලපාන්නේ නැහැ**. බාහිර කණ්ඩායමක් (උදා: performance) හැසිරීමෙන් හොයාගත් ව්‍යුහයට ගැලපෙනවද කියලා check කරන්න මේකෙන් පුළුවන්.
- `res_mca` print කළාම ඇතුළේ තියෙන දේවල් ලැයිස්තුගත කරනවා: `$eig`, `$var$coord`, `$var$cos2`, `$var$contrib`, `$var$v.test`, `$var$eta2`, `$ind$coord`, `$ind$cos2`, `$ind$contrib`, `$quali.sup$coord`, `$quali.sup$cos2`, `$quali.sup$v.test`...
- `graph = TRUE` නම් (lecture code එකෙත් තියෙනවා) MCA එකෙන් default factor maps වහාම අඳිනවා.

4.4 Eigenvalues සහ dimensions ගණන

```
res_mca$eig
fviz_eig(res_mca, addlabels = TRUE)
```

Dimension	Eigenvalue	Inertia %	Cumulative %
Dim 1	0.2910	14.55	14.55
Dim 2	0.1783	8.91	23.46
Dim 3	0.1557	7.78	31.25
Dim 4	0.1481	7.41	38.65
Dim 5	0.1361	6.81	45.46
…	…	…	…
Dim 18	0.0433	2.16	100.00

Active variables 9 ක් (J), categories 27 ක් (K) තියෙන නිසා K − J = **dimensions 18**. මුළු inertia = 27/9 − 1 = 2, සහ 0.2910/2 = 14.55%.



Checkpoint 2 – උත්තර

1. **Dim 1** වැඩිම කොටස පැහැදිලි කරනවා: inertia වලින් 14.55%.
2. Dim 1 න් පස්සේ පැහැදිලි පහත වැටීමක් (14.5% → 8.9%), ඊට පස්සේ Dims 2–7 හෙමින් අඩු වෙනවා (8.9, 7.8, 7.4, 6.8, 6.4, 6.0%). ඒ නිසා **Dim 2 න් පස්සේ ඉතා තියුණු elbow එකක් නැහැ**; ප්‍රධාන "elbow" එක Dim 1 හෝ 2 න් පස්සේ. (MCA වල පොදු නීතියක්: සාමාන්‍යය 1/J = 1/9 = 0.111 ට වැඩි eigenvalues ඇති dimensions තියාගන්න → එතකොට 7ක්.)
3. **නැහැ.** Dimensions දෙක (23.5%) කියවන්න ලේසි map එකකට සහ අර්ථකථනයට හොඳයි, නමුත් ඒවා **"data එක" නෙවෙයි**. Clustering හෝ prediction සඳහා තව තියාගන්න පුළුවන් (උදා: 5), මොකද පසු dimensions වලත් තොරතුරු ගොඩක් තියෙනවා.

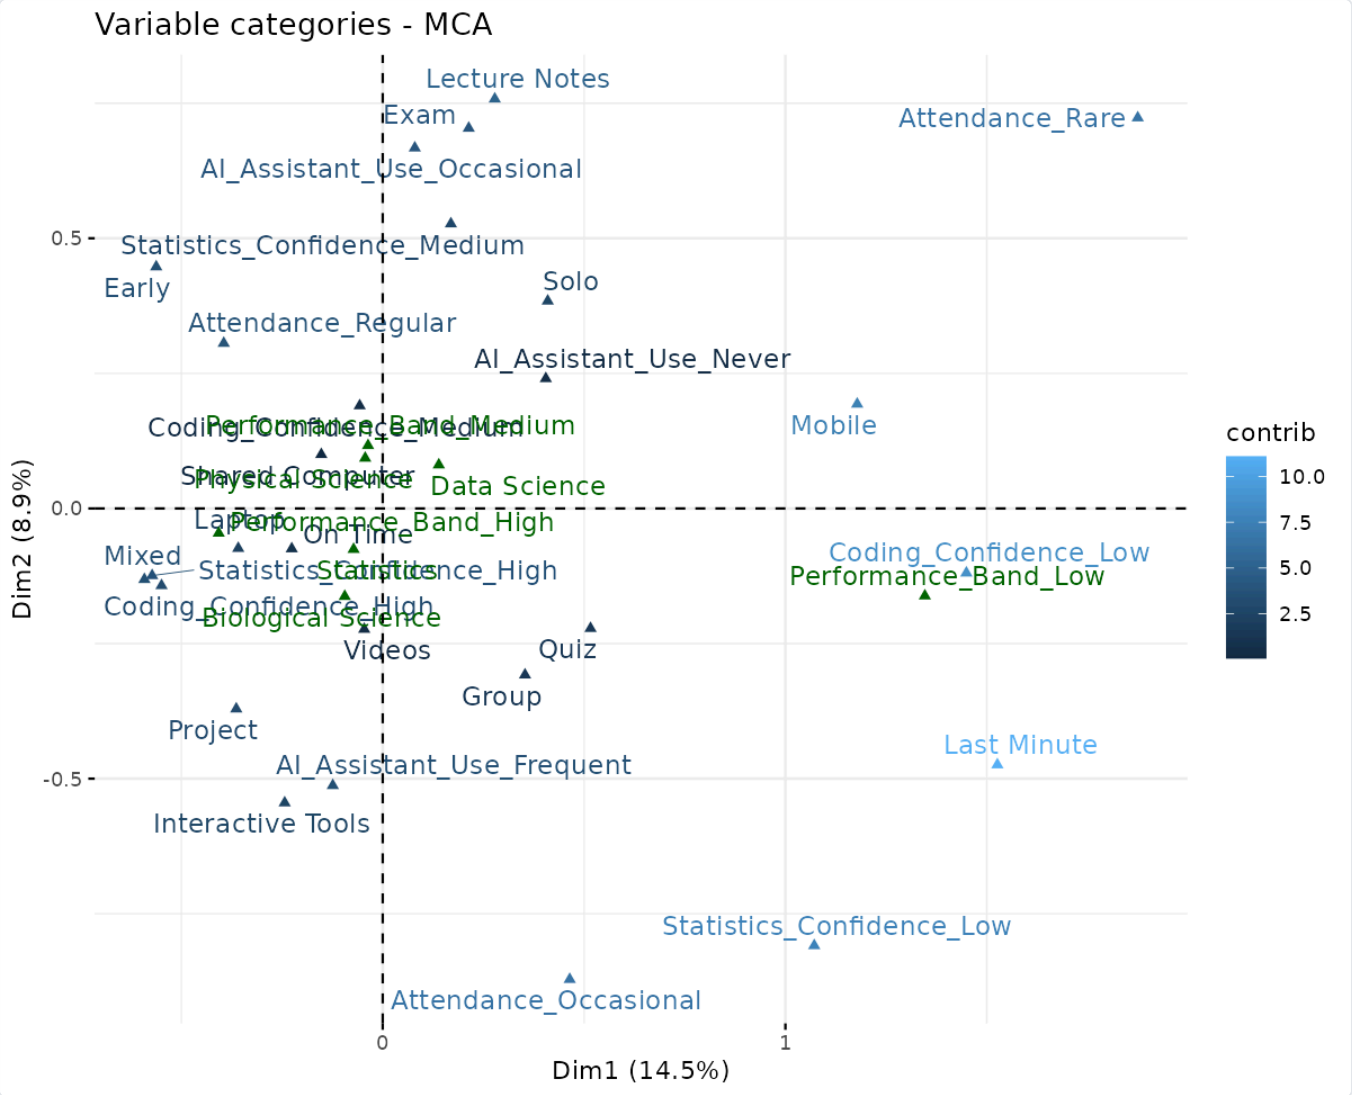
Inertia ප්‍රතිශත ගැන සටහන

MCA ප්‍රතිශත PCA ට වඩා සාමාන්‍යයෙන් **අඩුයි**, මොකද 0/1 coding එකෙන් කෘත්‍රිම dimensions ගොඩක් හැදෙනවා. "80% වෙනකම් dimensions තියාගන්න" වගේ ස්වයංක්‍රීය නීතියක් **යොදන්න එපා**. Coding එක සහ අරමුණ ගැන හිතන්න. (Benzécri adjustment වගේ නිවැරදි කළ ක්‍රම වලින් වඩා යථාර්ථවාදී, ඉහළ ප්‍රතිශත ලැබෙනවා.)

4.5 Categories plot කිරීම

```
fviz_mca_var(res_mca, choice = "var.cat", repel = TRUE)
fviz_mca_var(res_mca, choice = "var.cat", col.var = "contrib", repel = TRUE)
```

- `choice = "var.cat"` **categories** plot කරනවා. `repel = TRUE` labels එකිනෙක මත වැටීම වළක්වනවා. `col.var = "contrib"` හැම category එකක්ම contribution එක අනුව පාට කරනවා (ලා නිල් = වැඩි). Supplementary categories කොළ පාටින්.



Contribution අනුව පාට කළ MCA category map එක (ඔයාගේ data)

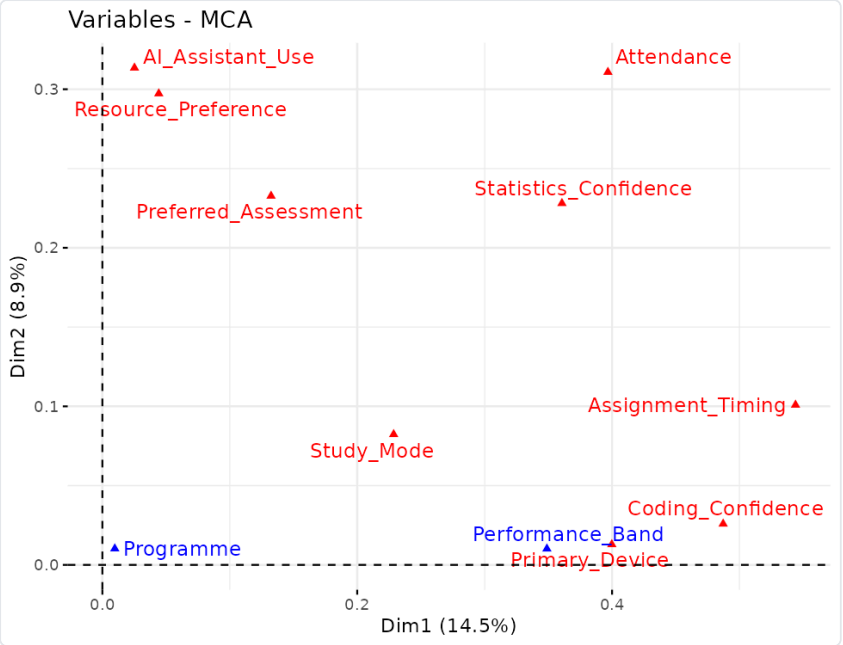
Map එක කියවීම:

- **Dim 1 දකුණු පැත්ත:** Last Minute, Coding_Confidence_Low, Mobile, Attendance_Rare, Statistics_Confidence_Low – සහ supplementary Performance_Band_Low.

- **Dim 1 වම් පැත්ත:** Early, Attendance_Regular, Coding/Statistics_Confidence_High, Laptop, Mixed study mode, Project – Performance_Band_High අසල.
- **Dim 2 ඉහළ:** Lecture Notes, Exam, AI_Assistant_Use_Occasional, Statistics_Confidence_Medium, Solo.
- **Dim 2 පහළ:** Attendance_Occasional, Statistics_Confidence_Low, Interactive Tools, AI_Assistant_Use_Frequent, Project.

තවත් ප්‍රයෝජනවත් දසුනක්, **variables** map එක (Dims 1 සහ 2 මත හැම variable එකකම η^2):

```
fviz_mca_var(res_mca, choice = "var", repel = TRUE)
```

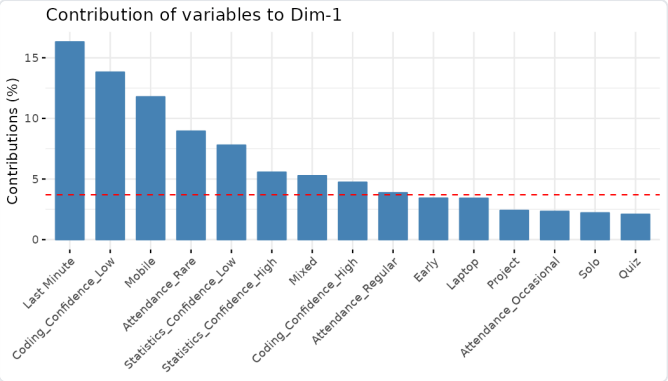


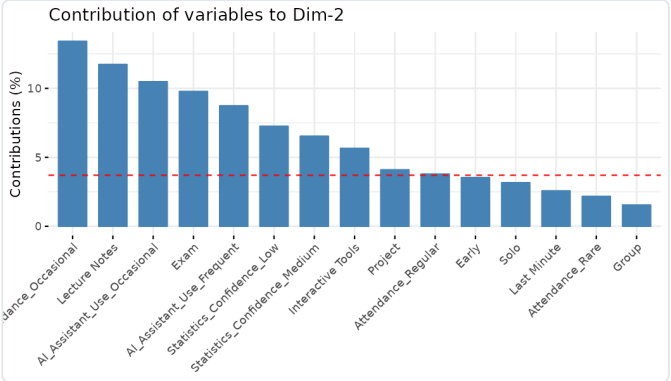
Variable	η^2 Dim 1	η^2 Dim 2
Assignment_Timing	**0.544**	0.101
Coding_Confidence	**0.487**	0.026
Primary_Device	**0.400**	0.013
Attendance	**0.397**	**0.311**
Statistics_Confidence	0.361	0.228
Study_Mode	0.229	0.082
Preferred_Assessment	0.132	0.233
Resource_Preference	0.044	**0.297**
AI_Assistant_Use	0.025	**0.313**

4.6 Contributions: dimension එක හදන්නේ කවුද?

```
fviz_contrib(res_mca, choice = "var", axes = 1, top = 15)
fviz_contrib(res_mca, choice = "var", axes = 2, top = 15)
head(res_mca$var$contrib[order(res_mca$var$contrib[,1], decreasing = TRUE), ], 12)
```

- **විශාල contribution එකක්** = ඒ dimension එක **හදන්න** category එක වැදගත්.
- `fviz_contrib` එකේ **රතු කැඩුණු රේඛාව** සාමාන්‍ය contribution එක = 100/27 = 3.7%. ඊට ඉහළ categories "වැදගත්".
- `order(..., decreasing = TRUE)` Dim 1 column එක අනුව පේළි පිළිවෙළට සකසනවා, `head(..., 12)` ඉහළම 12 පෙන්නනවා.





Dimension 1 – ඉහළම contributions			**Dimension 2 – ඉහළම contributions**		
Category	**contrib %**	**coord**	**Category**	**contrib %**	**coord**
Last Minute	16.31	+1.53	Attendance_Occasional	13.41	−0.87
Coding_Confidence_Low	13.82	+1.45	Lecture Notes	11.73	+0.76
Mobile	11.78	+1.18	AI_Assistant_Use_Occasional	10.48	+0.67
Attendance_Rare	8.95	+1.88	Exam	9.78	+0.70
Statistics_Confidence_Low	7.79	+1.07	AI_Assistant_Use_Frequent	8.74	−0.51
Statistics_Confidence_High	5.56	−0.57	Statistics_Confidence_Low	7.25	−0.81
Mixed	5.27	−0.59	Statistics_Confidence_Medium	6.54	+0.53
Coding_Confidence_High	4.74	−0.55	Interactive Tools	5.65	−0.55
Attendance_Regular	3.87	−0.40	Project	4.10	−0.37

Checkpoint 3 – උත්තර

Dimension 1

1. ඉහළම පහ: Last Minute, Coding_Confidence_Low, Mobile, Attendance_Rare, Statistics_Confidence_Low.
2. ඔව්, පැහැදිලි ප්‍රතිවිරෝධයක්: ධන පැත්තේ "අවදානම් (at-risk)" categories ඔක්කොම; සෘණ පැත්තේ Regular attendance, Early submission, High confidence, Laptop සහ Mixed study mode.
3. **අර්ථකථනය:** Dim 1 මගින් **ඉගෙනුමෙන් ඈත් වූ / අවදානම් ශිෂ්‍යයන්** (අන්තිම මොහොතේ, කලාතුරකින් පැමිණෙන, අඩු විශ්වාසය, mobile විතරයි) **සක්‍රීය, විශ්වාසවන්ත, හොඳ උපකරණ ඇති ශිෂ්‍යයන්** ගෙන් වෙන් කරනවා.

Dimension 2

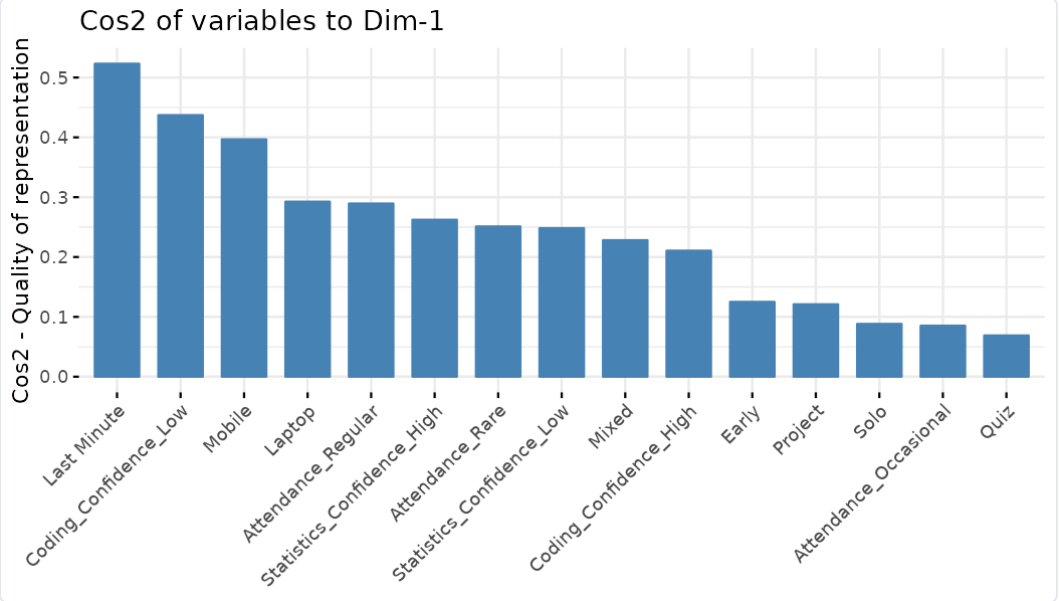
1. ඉහළම පහ: Attendance_Occasional, Lecture Notes, AI_Assistant_Use_Occasional, Exam, AI_Assistant_Use_Frequent.
2. ඔව්: ධන පැත්ත = Lecture Notes, Exam කැමැත්ත, Occasional AI භාවිතය, Medium statistics confidence, Solo; සෘණ පැත්ත = Occasional attendance, Interactive Tools, Frequent AI භාවිතය, Projects, Low statistics confidence.
3. **අර්ථකථනය:** Dim 2 මගින් **සාම්ප්‍රදායික, exam/notes පදනම් ඉගෙනුම් විලාසය interactive, project සහ AI-සහාය ඇති විලාසයෙන්** (බොහෝ විට occasional attendance සමඟ) වෙන් කරනවා.

4.7 cos2: category එකක් හොඳින් නිරූපණය වෙලාද?

```
fviz_cos2(res_mca, choice = "var", axes = 1, top = 15)

category_cos2_2d <- rowSums(res_mca$var$cos2[, 1:2])
sort(category_cos2_2d, decreasing = TRUE)[1:15]
```

- `rowSums(... [,1:2])` Dim 1 සහ Dim 2 මත cos2 එකතු කරනවා → **plane** එක මත නිරූපණයේ ගුණාත්මකභාවය. ඊට පස්සේ sort කරලා ඉහළම 15 පෙන්නනවා.



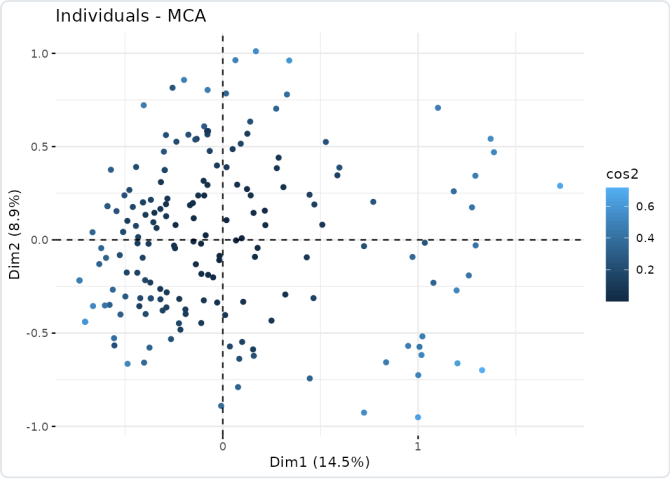
Category	cos2 (Dim 1 + 2)	Category	cos2 (Dim 1 + 2)
Last Minute	0.574	AI_Assistant_Use_Frequent	0.318
Attendance_Regular	0.463	Lecture Notes	0.318
Coding_Confidence_Low	0.440	Laptop	0.305
Mobile	0.407	Attendance_Rare	0.288
Statistics_Confidence_Low	0.390	Statistics_Confidence_High	0.275
Attendance_Occasional	0.386	AI_Assistant_Use_Occasional	0.274

Category එකකට **ඉහළ contribution** එකක් තිබිලත් **මධ්‍යම cos2** එකක් විතරක් තියෙන්න පුළුවන්. උදාහරණය: Attendance_Rare, Dim 1 ට 4 වන විශාලතම contribution එක (8.95%) දෙනවා, නමුත් plane එකේ පෙන්නන්නේ 0.288 ක් විතරයි – ඒක දුර්ලභ නිසා (ශිෂ්‍යයන් 12) origin එකෙන් ඈතින් තියෙනවා, අනිත් dimensions වලටත් පැතිරෙනවා. පරිස්සමෙන් අර්ථකථනය කරන්න.

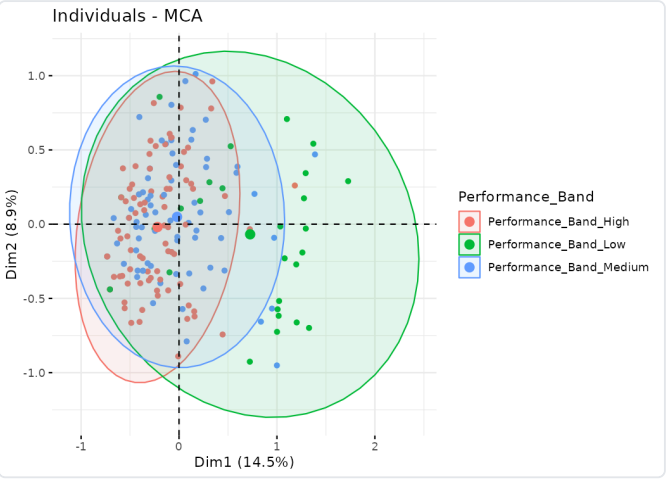
4.8 Individuals (ශිෂ්‍යයන්)

```
fviz_mca_ind(res_mca, geom = "point", col.ind = "cos2")
student_coordinates <- as.data.frame(res_mca$ind$coord)
head(student_coordinates)
```

- `geom = "point"` labels නැතුව points අඳිනවා. **ශිෂ්‍යයන් 180 ම label කරන්න එපා** – graph එක කියවන්න බැරි වෙනවා. `col.ind = "cos2"` ශිෂ්‍යයන් කොච්චර හොඳින් නිරූපණය වෙලාද කියන එක අනුව පාට කරනවා.



cos2 අනුව පාට කළ ශිෂ්‍යයන්



අමතර: `habillage = "Performance_Band", addEllipses = TRUE` සමඟ Performance_Band අනුව පාට කළා

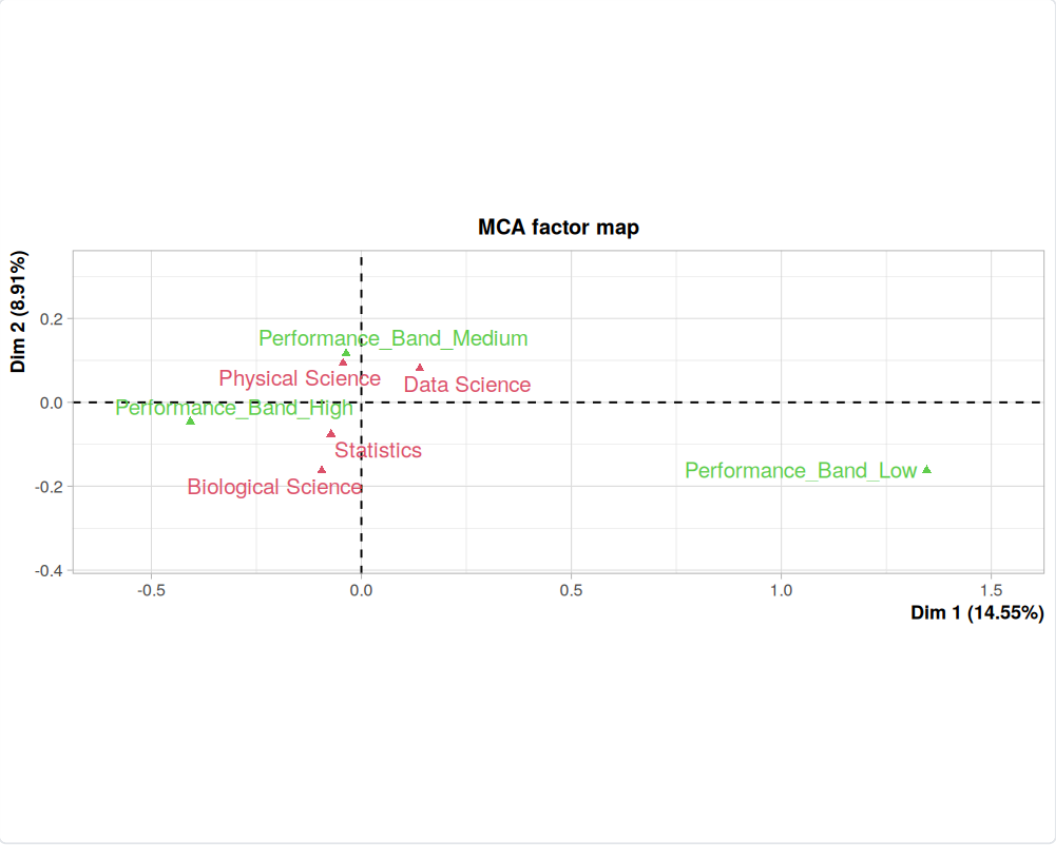
ශිෂ්‍යයා	Dim 1	Dim 2	Dim 3	Dim 4	Dim 5
S001	0.157	0.145	0.050	−1.223	−0.091
S002	−0.265	−0.532	−0.391	−0.195	−0.393
S003	−0.369	−0.314	−0.593	−0.315	0.465
S004	−0.705	−0.439	−0.099	−0.005	−0.354
S005	−0.368	0.215	−0.483	−0.161	−0.063
S006	0.587	0.346	0.499	−1.084	−0.346

මේ අංක හැම ශිෂ්‍යයෙකුගේම categorical profile එකේ **අඩු කළ සංඛ්‍යාත්මක නිරූපණයක්** – categories 9 වෙනුවට අංක 5ක්. පස්සේ visualisation හෝ clustering සඳහා භාවිතා කරන්න පුළුවන්.

4.9 Supplementary variables

```
res_mca$quali.sup$coord
plot(res_mca, invisible = c("ind", "var"), hab = "quali")
```

- `invisible = c("ind","var")` ශිෂ්‍යයන් සහ active categories සඟවනවා, ඒ නිසා **supplementary categories** විතරක් පේනවා. `hab = "quali"` variable එක අනුව ඒවා පාට කරනවා.



Supplementary category	Dim 1 coord	Dim 2 coord	v.test Dim 1	v.test Dim 2
Performance_Band_High	−0.407	−0.046	**−5.04**	−0.56
Performance_Band_Medium	−0.036	0.117	−0.39	1.24
Performance_Band_Low	**1.346**	−0.162	**7.57**	−0.91
Biological Science	−0.094	−0.163	−0.58	−0.99
Data Science	0.139	0.081	1.30	0.75
Physical Science	−0.044	0.093	−0.32	0.69
Statistics	−0.072	−0.076	−0.58	−0.61

Dim 1 සමඟ η^2: Performance_Band = 0.349, Programme = 0.010.

ප්‍රශ්න වලට උත්තර

1. **Performance_Band:** Low, Dim 1 හි **දකුණට** ඇතින් (+1.35, v.test 7.57), last-minute, අඩු විශ්වාසය, mobile, rare-attendance categories තියෙන පැත්තේම. High **වමට** (−0.41, v.test −5.04), සක්‍රීය categories එක්ක. Medium origin එකට ළඟ. Dim 2 මත කිසිවක් ශක්තිමත්ව පිහිටලා නැහැ.
2. **Programme** වෙන් වෙලා **නැහැ**: programmes හතරම origin එකට ළඟ, ඔක්කොම $|v.test| < 2$, සහ $\eta^2 \approx 0.01$. Programmes අතර ඉගෙනුම් හැසිරීම සමානයි වගේ.
3. **ඔව්**, MCA හොයාගත් හැසිරීම් ව්‍යුහය (Dim 1) axes හදන්න performance භාවිතා නොකළත් performance එක්ක පැහැදිලිව **සම්බන්ධයි (associated)**.
4. **හේතුඵල සම්බන්ධයක් (causality) නෙවෙයි:** මේක නිරීක්ෂණ data සහ සම්බන්ධයක් විතරයි. වෙනත් සාධක (පෙර දැනුම, වැඩ බර, අභිප්‍රේරණය, සෞඛ්‍යය, පවුල) හැසිරීම සහ performance දෙකටම හේතු වෙන්න පුළුවන්, නැත්නම් අඩු performance නිසා අඩු විශ්වාසය ඇති වෙන්න පුළුවන් (ප්‍රතිවිරුද්ධ දිශාව). ඒ සඳහා සැලසුම් කළ පරීක්ෂණයක් හෝ causal analysis එකක් ඕන.

4.10 Dimensions ස්වයංක්‍රීයව විස්තර කිරීම: dimdesc()

```
dimdesc(res_mca, axes = 1:2)
```

හැම dimension එකකටම මේක දෙනවා (1) ඊට වැඩිපුරම සම්බන්ධ **variables** (coordinates variable එක මත one-way ANOVA එකකින් ලැබෙන R^2, p-value සමඟ), සහ (2) **categories** ("Estimate" එකක් – ධන = ධන පැත්තේ – p-value සමඟ). ඔයාගේ data වල සාරාංශය:

Dim 1 – variables (R^2)	Dim 2 – variables (R^2)
Assignment_Timing 0.544, Coding_Confidence 0.487, Primary_Device 0.400, Attendance 0.397, Statistics_Confidence 0.361, **Performance_Band 0.349**, Study_Mode 0.229, Preferred_Assessment 0.132, Resource_Preference 0.044	AI_Assistant_Use 0.313, Attendance 0.311, Resource_Preference 0.297, Preferred_Assessment 0.233, Statistics_Confidence 0.228, Assignment_Timing 0.101, Study_Mode 0.082
+ Last Minute, Coding Low, Mobile, Performance Low, Attendance Rare, Stats Low, Solo, Quiz … − Laptop, Attendance Regular, Stats High, Mixed, Coding High, Performance High, Early, Project	+ Lecture Notes, AI Occasional, Exam, Attendance Regular, Stats Medium, Early, Solo … − AI Frequent, Attendance Occasional, Stats Low, Interactive Tools, Project, Last Minute, Group, Videos

`dimdesc` ඔයාගේම අර්ථකථනය වෙනුවට නෙවෙයි, **රෝග විනිශ්චය උපකාරයක් (diagnostic aid)** විදිහට භාවිතා කරන්න.

4.11 අමතර සැසඳීම: Indicator සහ Burt ක්‍රම

```
res_indicator <- MCA(dat, quali.sup = sup_idx, method = "Indicator", graph = FALSE)
res_burt      <- MCA(dat, quali.sup = sup_idx, method = "Burt",      graph = FALSE)
res_indicator$eig[1:5, ]
res_burt$eig[1:5, ]
```

Dim	Indicator eigenvalue	Indicator %	Burt eigenvalue	Burt %
1	0.2910	14.55	0.0847	30.14
2	0.1783	8.91	0.0318	11.31
3	0.1557	7.78	0.0242	8.63
4	0.1481	7.41	0.0219	7.81
5	0.1361	6.81	0.0185	6.60

- **Indicator** ක්‍රමය (default) 180 × 27 0/1 table එක analyse කරනවා. **Burt** ක්‍රමය 27 × 27 Burt table එක (categories වල ඔක්කොම two-way cross-tables) analyse කරනවා.
- **වෙනස් වෙන දේ:** Burt eigenvalues කියන්නේ indicator eigenvalues වල **වර්ග** ($0.2910^2 = 0.0847$), ඒ නිසා ප්‍රතිශත ගොඩක් ලොකුයි වගේ පේනවා (30% vs 14.5%), category coordinates වල පරිමාණයත් වෙනස් වෙනවා.
- **එහෙමම තියෙන දේ:** dimensions වල **දිශා**, dimensions වල පිළිවෙළ සහ categories වල සාපේක්ෂ පිහිටීම් – අර්ථකථනය සාරාංශයෙන් සමානයි.
- Eigenvalue පරිමාණය ගැන නිගමනවලට එන්න කලින් `?MCA` බලන්න.

4.12 Mini-report – ආදර්ශ උත්තරයක් (වචන 300 පමණ)

(Report එක ඉංග්‍රීසියෙන් ලියන්න ඕන නිසා මෙතන ඉංග්‍රීසියෙන්ම තියෙනවා.)

Why MCA? All nine active variables (study mode, resources, attendance, assignment timing, confidence levels, AI use, assessment preference and device) are categorical. PCA needs quantitative variables and Euclidean distances; coding categories as numbers would invent distances. MCA analyses the indicator table of categories directly.

How many dimensions? Dim 1 explains 14.5% and Dim 2 8.9% of inertia (23.5% together). The scree plot drops clearly after Dim 1 and then declines slowly. I keep **two dimensions for interpretation**, but would keep about five for clustering, since MCA percentages are naturally low.

Dimension 1 – "Engagement / at-risk learning behaviour". The positive side is formed by Last Minute submission (16.3%), Low coding confidence (13.8%), Mobile device (11.8%), Rare attendance (9.0%) and Low statistics confidence (7.8%); the negative side by Regular attendance, Early submission, High confidence, Laptop and Mixed study.

Dimension 2 – "Traditional vs interactive learning style". Lecture Notes, Exam preference and Occasional AI use are on the positive side; Occasional attendance, Interactive Tools, Frequent AI use and Projects on the negative side.

High contributions: Last Minute, Coding_Confidence_Low and Mobile (Dim 1); Attendance_Occasional and Lecture Notes (Dim 2).

Representation: the key categories are moderately well represented on the plane: Last Minute cos2 = 0.57, Coding_Confidence_Low 0.44, Mobile 0.41, Attendance_Occasional 0.39. Attendance_Rare (0.29) is rarer and less well represented, so it is interpreted with care.

Performance_Band (supplementary): Low performance lies far on the positive side of Dim 1 (v.test 7.6) and High on the negative side (v.test −5.0); Programme is near the origin. So the behavioural pattern is associated with performance, but this does not prove that behaviour causes performance.

ඇතුළත් කරන්න: scree plot එක (4.4), category map එක (4.5) සහ contribution plot එකක් (4.6).

5. FAMD – අදහස

Factor Analysis of Mixed Data (FAMD) භාවිතා කරන්නේ data වල quantitative සහ categorical variables **දෙකම** තියෙනකොට. ඒක PCA සහ MCA වල සංයෝජනයක්:

- **Quantitative variables standardise** කරනවා (correlation matrix එක මත PCA වගේ).
- **Categorical variables** indicator columns විදිහට code කරලා MCA වගේ **බර (weight)** දෙනවා.
- මේකෙන් වර්ග දෙක **සමබර** කරනවා, coding එක නිසාම එකක් අනිකට ආධිපත්‍යය ගන්නේ නැහැ.
- හැම dimension එකක්ම quantitative variables වලට **squared correlation** එකෙන්ද, categorical variables වලට **η² (correlation ratio)** එකෙන්ද සම්බන්ධයි. Dimension එකක eigenvalue එක = මේ අගයන්ගේ එකතුව.

6. FAMD පියවරෙන් පියවර

Data: `graduate_employability_mixed.csv` – උපාධිධාරීන් 180. (Upload කළ copies දෙක, "graduate_employability_mixed.csv" සහ "... 1.csv", එකමයි.)

6.1 කියවීම සහ සූදානම් කිරීම

```
dat <- read.csv("graduate_employability_mixed.csv", stringsAsFactors = TRUE)
str(dat)
head(dat)
rownames(dat) <- dat$Graduate_ID
dat$Graduate_ID <- NULL
head(dat)
sapply(dat, class)
```

6.2 Part C Task 1 – quantitative සහ categorical variables වෙන් කිරීම

```
num_vars <- names(dat)[sapply(dat, is.numeric)]
num_vars;  length(num_vars)     # 8
cat_vars <- names(dat)[sapply(dat, is.factor)]
cat_vars;  length(cat_vars)     # 6
```

- `sapply(dat, is.numeric)` numeric/integer columns වලට TRUE දෙනවා; `names(dat)[...]` TRUE ඒවායේ නම් තියාගන්නවා. මෙතන මේක වැඩ කරන්නේ categorical columns ඇත්ත **factors** (text) නිසා – පසුගිය සතියේ mtcars වල vs/am වගේ නෙවෙයි.

Quantitative (8)	Categorical (6)
GPA, Programming_Score, Statistics_Score, Communication_Score, Internship_Months, Portfolio_Projects, Weekly_SelfStudy_Hours, Hackathons	Degree_Stream (levels 4), Internship_Sector (5), English_Level (3), Teamwork_Level (3), Career_Preference (5), **Employment_Status** (4) – supplementary

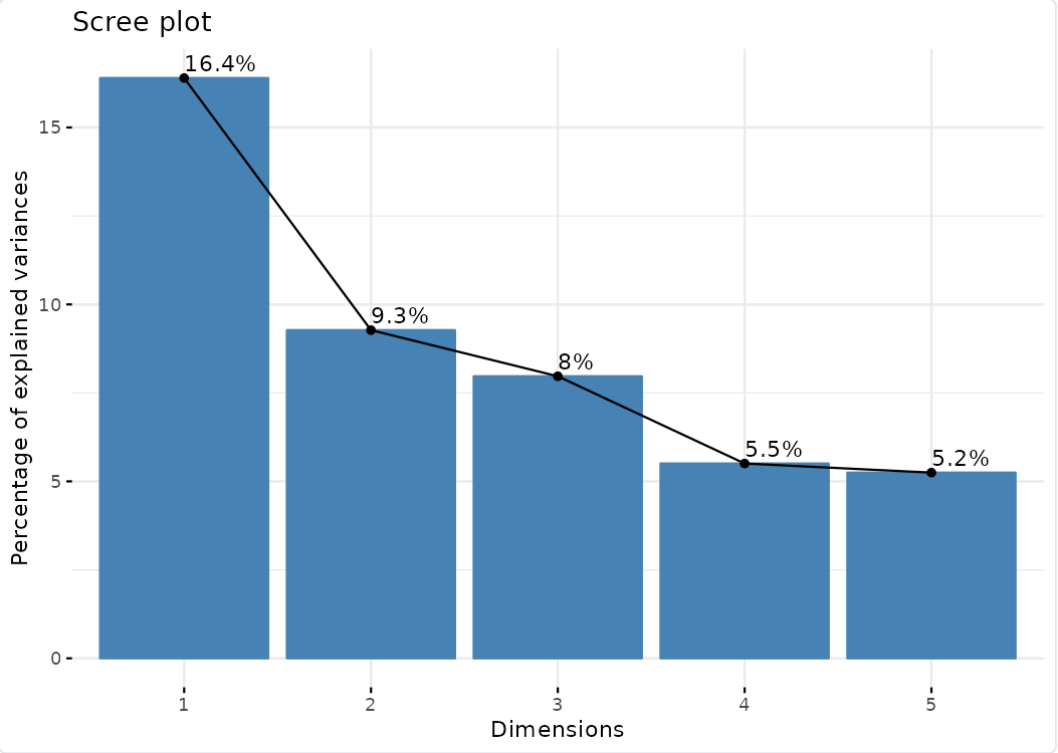
Frequencies: Degree_Stream – Bioinformatics 11, Computer Science 50, Data Science 62, Statistics 57. English_Level – Advanced 115, Basic 20, Intermediate 45. Teamwork – Competent 69, Developing 23, Strong 88. Employment_Status – Employed-Data Role 103, Employed-Other 26, Higher Studies 23, Seeking 28. (Means: GPA 3.31, Programming 72.4, Statistics 75.7, Communication 75.2.)

6.3 FAMD run කිරීම (Task 2)

```
sup_idx <- which(names(dat) == "Employment_Status")     # 14
res_famd <- FAMD(dat, sup.var = sup_idx, ncp = 5, graph = FALSE)
res_famd$eig
fviz_eig(res_famd, addlabels = TRUE)
```

- `FAMD()` වල argument එක `sup.var` (quantitative හෝ categorical වෙන්න පුළුවන්). Employment_Status කියන්නේ **ප්‍රතිඵලය (outcome)**, ඒ නිසා supplementary විදිහට තියනවා: axes හදන්නේ නැහැ, ඒක වැටෙන්නේ කොහේද කියලා බලනවා විතරයි.

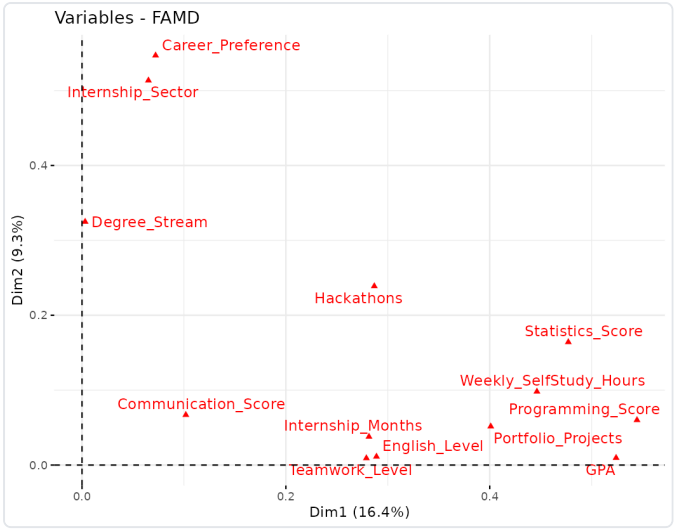
Dim	Eigenvalue	%	Cumulative %
1	3.771	16.40	16.40
2	2.133	9.27	25.67
3	1.833	7.97	33.64
4	1.266	5.50	39.14
5	1.207	5.25	44.39



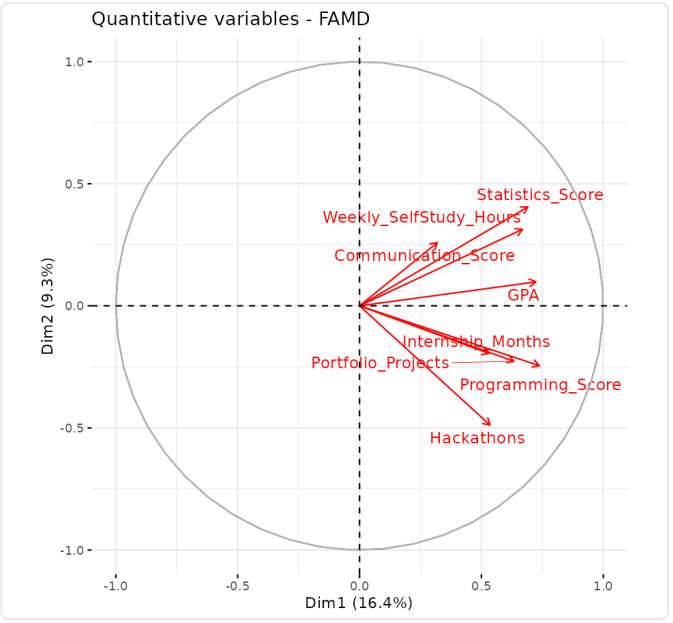
Dim 1 පැහැදිලිවම ශක්තිමත්ම එක; Dim 3 න් පස්සේ අගයන් පැතලි වෙනවා (elbow එක 3 පමණ). Dimensions දෙකකින් 25.7%, තුනකින් 33.6%.

6.4 Variables

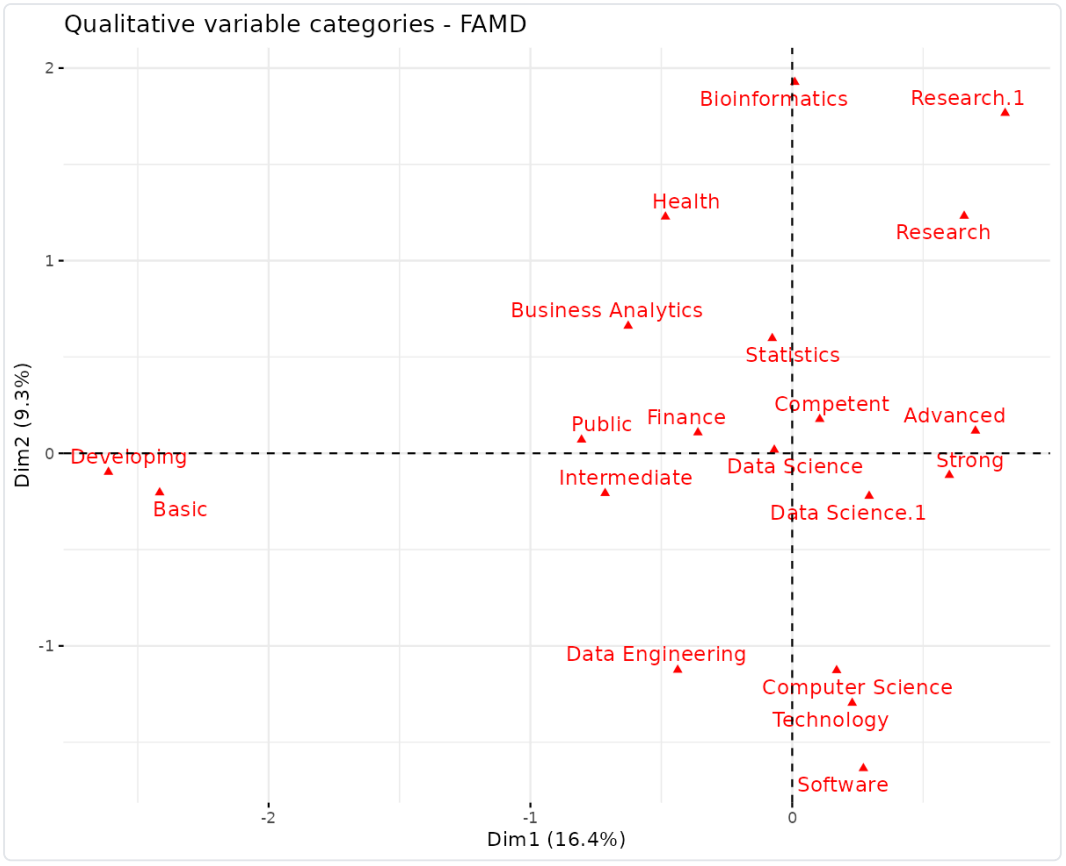
```
fviz_famd_var(res_famd, repel = TRUE)                          # ඔක්කොම variables
fviz_famd_var(res_famd, choice = "quanti.var", repel = TRUE)   # correlation circle
fviz_famd_var(res_famd, choice = "quali.var",  repel = TRUE)   # categories
```



ඔක්කොම variables: coordinates = squared correlation (numeric) හෝ η^2 (categorical)



Quantitative variables වල correlation circle



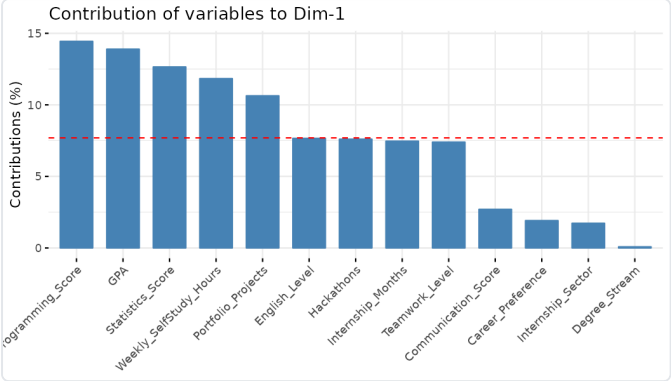
Qualitative variables වල categories

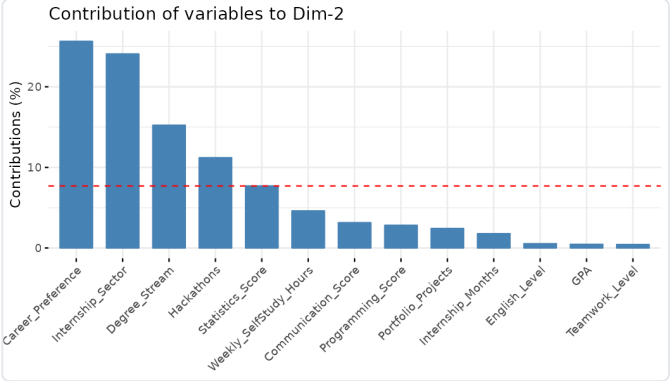
Tip: එකම නම ඇති categories

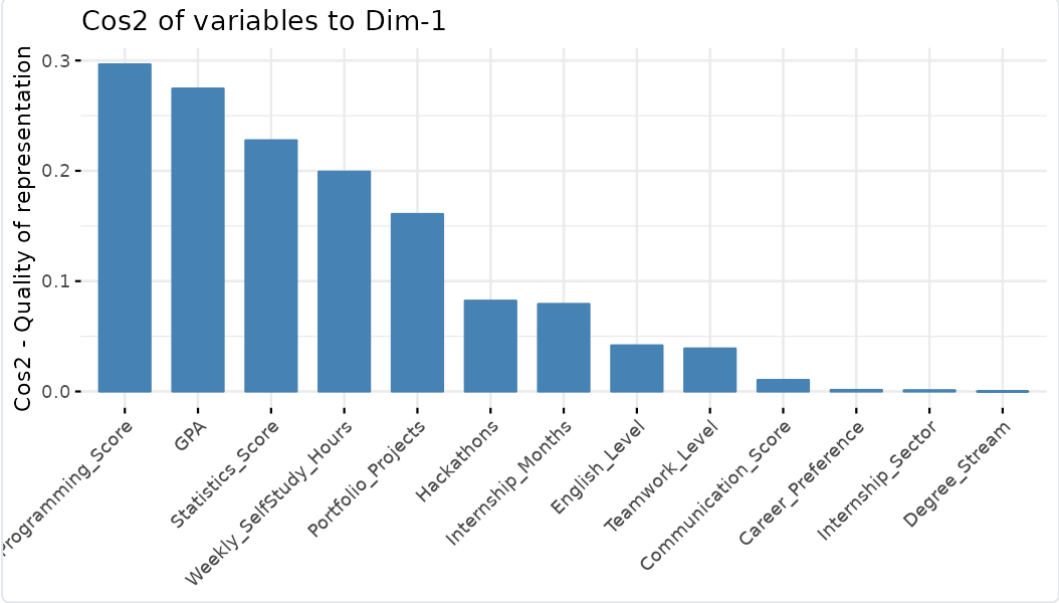
Degree_Stream සහ Career_Preference දෙකේම "Data Science" category එකක් තියෙනවා, Internship_Sector සහ Career_Preference දෙකේම "Research" තියෙනවා. FactoMineR දෙවැනි ඒවා **"Data Science.1"** සහ **"Research.1"** ලෙස නම් වෙනස් කරනවා (මේවා Career_Preference). ව්‍යාකූලත්වය වළක්වන්න මුලින් levels වල නම් වෙනස් කරන්න පුළුවන්, උදා: `levels(dat$Career_Preference) <- paste0("Career_", levels(dat$Career_Preference))`.

6.5 Contributions සහ නිරූපණය (Tasks 3, 4, 5)

```
fviz_contrib(res_famd, choice = "var", axes = 1, top = 15)
fviz_cos2(res_famd,    choice = "var", axes = 1, top = 15)
fviz_contrib(res_famd, choice = "var", axes = 2, top = 15)
```







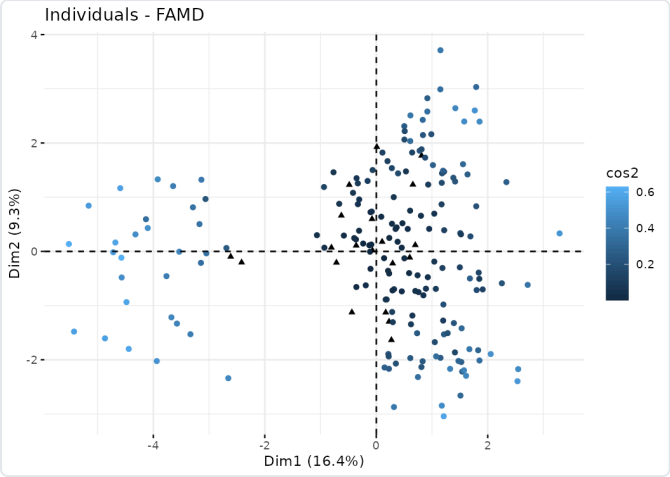
Variable	Contrib Dim 1 %	Contrib Dim 2 %	Dim 1 සමඟ correlation	Dim 2 සමඟ correlation
Programming_Score	**14.44**	2.82	0.738	−0.245
GPA	**13.89**	0.45	0.724	0.098
Statistics_Score	**12.65**	7.70	0.691	0.405
Weekly_SelfStudy_Hours	11.83	4.60	0.668	0.313
Portfolio_Projects	10.63	2.42	0.633	−0.227
English_Level	7.66	0.53	η^2 0.289	η^2 0.011
Hackathons	7.60	11.20	0.535	−0.489
Internship_Months	7.47	1.77	0.531	−0.195
Teamwork_Level	7.40	0.43	η^2 0.279	η^2 0.009
Communication_Score	2.70	3.14	0.319	0.259
Career_Preference	1.91	**25.64**	η^2 0.072	η^2 0.547
Internship_Sector	1.73	**24.08**	η^2 0.065	η^2 0.514
Degree_Stream	0.08	**15.23**	η^2 0.003	η^2 0.325

උත්තර

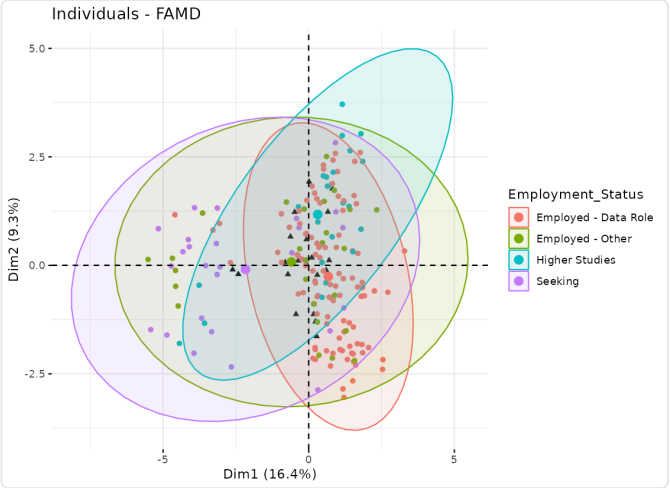
- **Task 3 – Dim 1 සඳහා වැදගත්ම quantitative variables තුන:** Programming_Score (14.4%), GPA (13.9%), Statistics_Score (12.7%). ඔක්කොම Dim 1 එක්ක ධන ලෙස correlated (≈ 0.7).
- **Task 4 – Dim 1 සඳහා වැදගත්ම qualitative categories:** සෘණ පැත්තේ Teamwork_Level = **Developing** (contrib 6.1%, coord −2.61) සහ English_Level = **Basic** (4.6%, −2.42); ධන පැත්තේ English_Level = **Advanced** (2.2%, +0.70) සහ Teamwork = **Strong** (1.2%, +0.60). සම්පූර්ණ variables විදිහට English_Level (7.7%) සහ Teamwork_Level (7.4%).
- ඒ නිසා **Dim 1 = "සමස්ත අධ්‍යයන සහ රැකියා හැකියාව (academic and employability strength)"**: ඉහළ GPA, ශක්තිමත් programming/statistics ලකුණු, වැඩි self-study, projects, hackathons සහ internships, advanced English සහ strong teamwork (දකුණ) එදිරිව basic English සහ developing teamwork ඇති දුර්වල profiles (වම).
- **Task 5 – Dim 2 = "research/health දිශානතිය එදිරිව technology/software දිශානතිය"**. ධන: Career = Research, Internship sector = Research / Health, Degree = Bioinformatics / Statistics, ඉහළ Statistics ලකුණු සහ self-study පැය. සෘණ: Internship sector = Technology, Career = Software / Data Engineering, Degree = Computer Science, වැඩි Hackathons. මේක ප්‍රධාන වශයෙන් හදන්නේ **categorical** variables (Career 25.6%, Sector 24.1%, Degree 15.2%).

6.6 Individuals

```
fviz_famd_ind(res_famd, geom = "point", col.ind = "cos2")
```



cos2 අනුව පාට කළ උපාධිධාරීන්



අමතර: Employment_Status අනුව පාට කළා (`habillage = "Employment_Status", addEllipses = TRUE`)

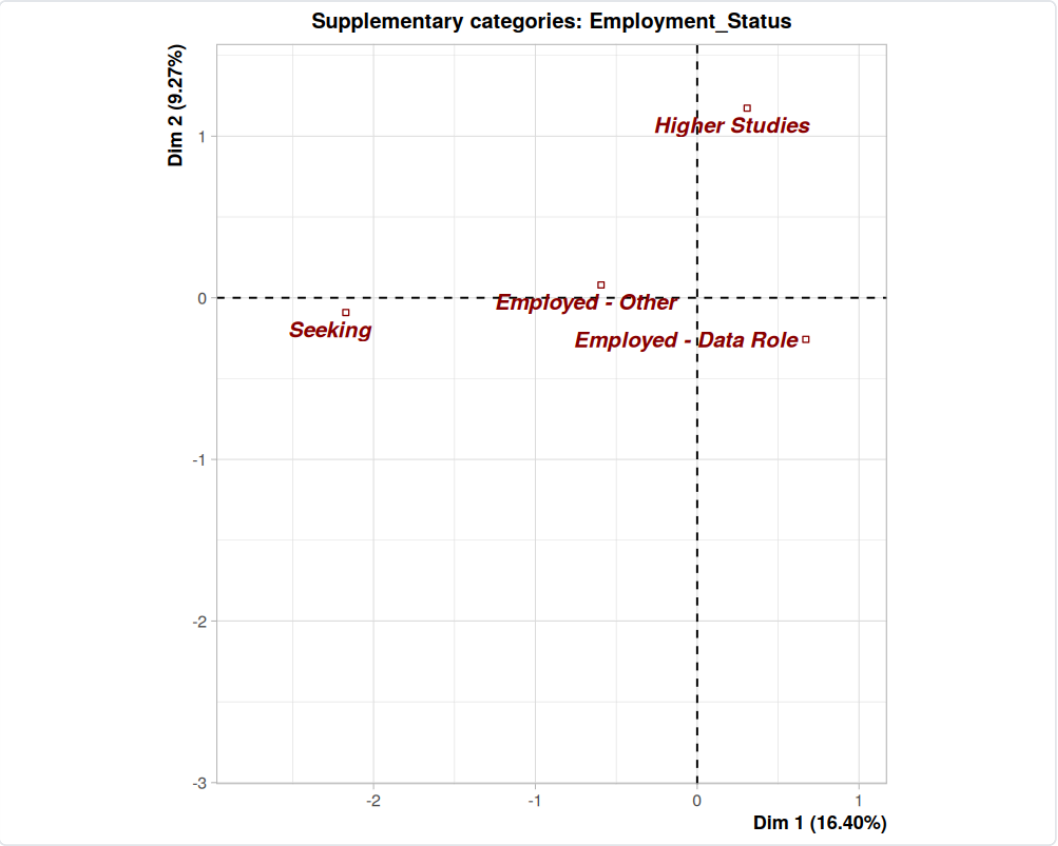
6.7 Supplementary outcome (Task 6)

```
# lecture code එකෙන් – වත්මන් factoextra වල ERROR එකක් දෙනවා:
fviz_famd_var(res_famd, choice = "quali.sup", repel = TRUE)
# Error: 'arg' should be one of "var", "quanti.var", "quali.var"

# වැඩ කරන විකල්පය:
plot(res_famd, choix = "ind", invisible = c("ind", "quali"),
     title = "Supplementary categories: Employment_Status")
res_famd$quali.sup$coord
res_famd$quali.sup$v.test
```

Code නිවැරදි කිරීම

`fviz_famd_var()` පිළිගන්නේ `"var"`, `"quanti.var"` හෝ `"quali.var"` විතරයි. ඉහත base `plot()` එක භාවිතා කරන්න (individuals සහ active categories සඟවලා supplementary ඒවා විතරක් පෙන්නනවා), නැත්නම් 6.6 වගේ `habillage` එකෙන් individuals පාට කරන්න.



Employment_Status	Dim 1	Dim 2	v.test Dim 1	v.test Dim 2
Employed – Data Role	0.671	−0.257	**5.35**	−2.73
Employed – Other	−0.594	0.079	−1.68	0.30
Higher Studies	0.309	**1.173**	0.81	**4.11**
Seeking	**−2.171**	−0.091	**−6.42**	−0.36

අර්ථකථනය: "Seeking" (රැකියා සොයන) උපාධිධාරීන් Dim 1 හි **දුර්වල** පැත්තේ ඈතින්; "Employed – Data Role" **ශක්තිමත්** පැත්තේ. "Higher Studies" Dim 2 හි ඉහළින් (research/health දිශානතිය). Employment_Status හි η^2: Dim 1 = 0.28, Dim 2 = 0.10. ආයෙත්: සම්බන්ධයක්, හේතුඵලයක් නෙවෙයි.

6.8 FAMD සඳහා dimdesc

```
dimdesc(res_famd, axes = 1:2)
```

- **Dim 1:** correlations – Programming 0.74, GPA 0.72, Statistics 0.69, Self-study 0.67, Portfolio 0.63, Hackathons 0.54, Internship months 0.53, Communication 0.32. Categorical – English_Level (R^2 0.29), Employment_Status (0.28), Teamwork (0.28). ධන categories: English Advanced, Employed-Data Role, Teamwork Strong; සෘණ: Teamwork Developing, Seeking, English Basic.
- **Dim 2:** correlations – Statistics 0.41, Self-study 0.31, Communication 0.26; සෘණ: Hackathons −0.49, Programming −0.25, Portfolio −0.23. Categorical – Career_Preference (R^2 0.55), Internship_Sector (0.51), Degree_Stream (0.32). ධන: Career Research, Sector Research,

Bioinformatics, Higher Studies, Sector Health; සෘණ: Sector Technology, Career Software, Computer Science, Career Data Engineering.

7. අඩු කළ coordinates clustering සඳහා භාවිතා කිරීම (Task 7, 8)

```
graduate_coordinates <- as.data.frame(res_famd$ind$coord)
graduate_coordinates             # පේළි 180 x columns 5 (Dim.1 ... Dim.5)
X <- graduate_coordinates[, 1:3] # පළමු coordinates තුන
```

උපාධිධාරියා	Dim.1	Dim.2	Dim.3
G001	1.526	−2.042	0.911
G002	0.988	2.161	0.867
G003	1.909	−0.702	1.530
G004	−0.235	0.144	−1.359
G005	0.811	−2.134	1.315
G006	−4.100	0.430	0.937

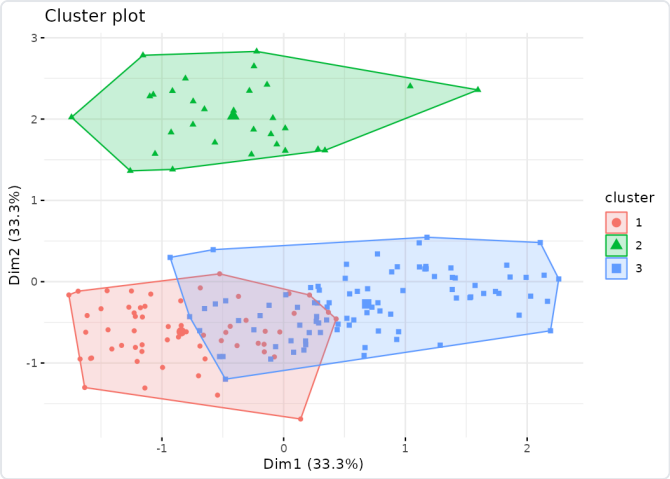
Task 7: `graduate_coordinates[, 1:3]` මගින් හැම උපාධිධාරියෙකුගේම Dims 1–3 coordinates ලැබෙනවා (පළමු පේළි ඉහත පෙන්වා ඇත).

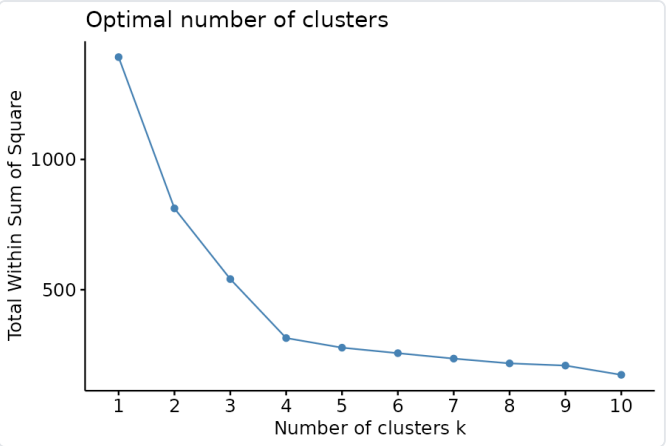
Task 8 – ඒවා clustering සඳහා භාවිතා කළ හැකි ආකාරය

- මිශ්‍ර variables 13 (අංක + categories) **සංඛ්‍යාත්මක, correlation නැති, සැසඳිය හැකි coordinates 3කින්** ආදේශ වෙනවා. සාමාන්‍ය දුර පදනම් ක්‍රම (**k-means**, **hierarchical clustering**) Euclidean දුර සමඟ ඒවා කෙලින්ම භාවිතා කරන්න පුළුවන් – raw categories මත කරන්න බැරි දෙයක්.
- පළමු dimensions ප්‍රධාන ව්‍යුහය තියාගෙන පසු dimensions වල **noise** වලින් වැඩි කොටසක් අතහරිනවා.
- Clustering එකෙන් පස්සේ, මුල් variables සහ dimension අර්ථයන් භාවිතා කරලා **හැම cluster එකක්ම විස්තර කරනවා** (උදා: "ශක්තිමත් අධ්‍යයන, technology දිශානත").

ප්‍රදර්ශනය (Dims 1–3 මත clusters 3ක k-means, `set.seed(123)`, `nstart = 25`):

```
set.seed(123)
km <- kmeans(X, centers = 3, nstart = 25)
km$size                                  # 59 30 91
table(km$cluster, dat$Employment_Status)
fviz_cluster(km, data = X, geom = "point")
```





k තෝරා ගැනීමට elbow plot එක

Cluster (ප්‍රමාණය)	මධ්‍යය (Dim1, Dim2, Dim3)	Data Role	Other	Higher Studies	Seeking	තේරුම
1 (59)	1.20, −1.48, 0.46	47	6	2	4	ශක්තිමත්, technology/software දිශානත
2 (30)	−3.97, −0.19, 0.56	4	6	3	**17**	දුර්වල අධ්‍යයන/රැකියා profile
3 (91)	0.53, 1.02, −0.48	52	14	18	7	මධ්‍යම-ශක්තිමත්, research/analytics දිශානත

Clusters හදන්න Employment_Status භාවිතා කළේ **නැහැ**, නමුත් cluster 2 හි "Seeking" උපාධිධාරීන්ගෙන් වැඩි දෙනෙක් ඉන්නවා.

8. Self-Learning Activity – උත්තර

Part A – ක්‍රමය තෝරා ගැනීම

තත්ත්වය	ක්‍රමය	හේතුව
1. Continuous laboratory මිනුම් 12	**PCA**	ඔක්කොම variables quantitative නිසා PCA (සාමාන්‍යයෙන් standardise කළ data මත) ස්වාභාවික තේරීම.
2. Yes/No සහ Likert ප්‍රශ්න 18ක survey එකක්	**MCA**	Categorical variables කිහිපයක්; MCA සංඛ්‍යාත්මක දුර නිර්මාණය නොකර ඒවා analyse කරනවා.
3. දිස්ත්‍රික්කය × ප්‍රවාහන ක්‍රමය contingency table එක	**CA**	Counts ඇති එක two-way table එකක් කියන්නේ Correspondence Analysis හදලා තියෙන්නෙම ඒකටයි.
4. GPA, test ලකුණු, degree stream, sector, career කැමැත්ත	**FAMD**	Quantitative සහ categorical variables මිශ්‍රණයක්; FAMD වර්ග දෙකම සමබර කරනවා.
5. Genetics, clinical, imaging සහ lifestyle blocks	**MFA**	Variables අර්ථවත් කණ්ඩායම් වලට එනවා; MFA blocks සමබර කරන නිසා එක block එකක් ආධිපත්‍යය ගන්නේ නැහැ.

Part B – Categorical data set

1. **Frequency සාරාංශය:** `lapply(dat, table)` – 4.2 හි table එක බලන්න.
2. **පළමු eigenvalues පහ:** 0.2910, 0.1783, 0.1557, 0.1481, 0.1361 (14.55%, 8.91%, 7.78%, 7.41%, 6.81%).
3. **Scree plot:** `fviz_eig(res_mca, addlabels = TRUE)` – 4.4 බලන්න.
4. **Dim 1 ඉහළම 5:** Last Minute (16.3%), Coding_Confidence_Low (13.8%), Mobile (11.8%), Attendance_Rare (9.0%), Statistics_Confidence_Low (7.8%).
5. **Dim 2 ඉහළම 5:** Attendance_Occasional (13.4%), Lecture Notes (11.7%), AI_Assistant_Use_Occasional (10.5%), Exam (9.8%), AI_Assistant_Use_Frequent (8.7%).
6. **පළමු dimensions දෙක මත ඉහළ ගුණාත්මකභාවය (cos2):** Last Minute 0.57, Attendance_Regular 0.46, Coding_Confidence_Low 0.44, Mobile 0.41, Statistics_Confidence_Low 0.39.
7. **නම්:** lecture code එකේ "Dim 1 – Learning Behaviour and Study Habits" සහ "Dim 2 – Learning Preferences and Engagement" භාවිතා කරනවා. Output එකෙන් වඩා නිශ්චිත නම්: **Dim 1 = සක්‍රීය එදිරිව අවදානම් ඉගෙනුම් හැසිරීම (Engaged vs at-risk)**; **Dim 2 = සාම්ප්‍රදායික (notes/exam) එදිරිව interactive (tools/projects/AI) ඉගෙනුම් විලාසය**.
8. **Performance_Band:** Low, Dim 1 හි අවදානම් පැත්තේ (coord 1.35, v.test 7.6), High සක්‍රීය පැත්තේ (−0.41, v.test −5.0), Medium මධ්‍යයට ළඟ. මේකෙන් පෙන්නන්නේ හැසිරීම් රටා සහ performance අතර **සම්බන්ධයක්**; හැසිරීම performance එකට **හේතු වෙනවා** කියලා නෙවෙයි.

Part C – Mixed data set

1. **ලැයිස්තු:** quantitative 8 (GPA, Programming_Score, Statistics_Score, Communication_Score, Internship_Months, Portfolio_Projects, Weekly_SelfStudy_Hours, Hackathons); categorical 6

(Degree_Stream, Internship_Sector, English_Level, Teamwork_Level, Career_Preference, Employment_Status).

2. **FAMD + scree plot:** 6.3 බලන්න (Dim 1 16.4%, Dim 2 9.3%, Dim 3 8.0%).
3. **Dim 1 ඉහළම quantitative:** Programming_Score, GPA, Statistics_Score.
4. **Dim 1 ඉහළම qualitative categories:** Teamwork = Developing සහ English = Basic (සෘණ), English = Advanced සහ Teamwork = Strong (ධන).
5. **Dim 2:** research/health/bioinformatics දිශානතිය එදිරිව technology/software/computer-science දිශානතිය (6.5 බලන්න).
6. **Supplementary employment categories:** 6.7 බලන්න – Seeking Dim 1 හි සෘණ පැත්තේ ඈතින්, Data Role Dim 1 හි ධන, Higher Studies Dim 2 හි ඉහළ.
7. **පළමු coordinates තුන:** `graduate_coordinates[, 1:3]` (7 කොටස බලන්න).
8. **Clustering සඳහා භාවිතය:** 7 කොටස බලන්න.

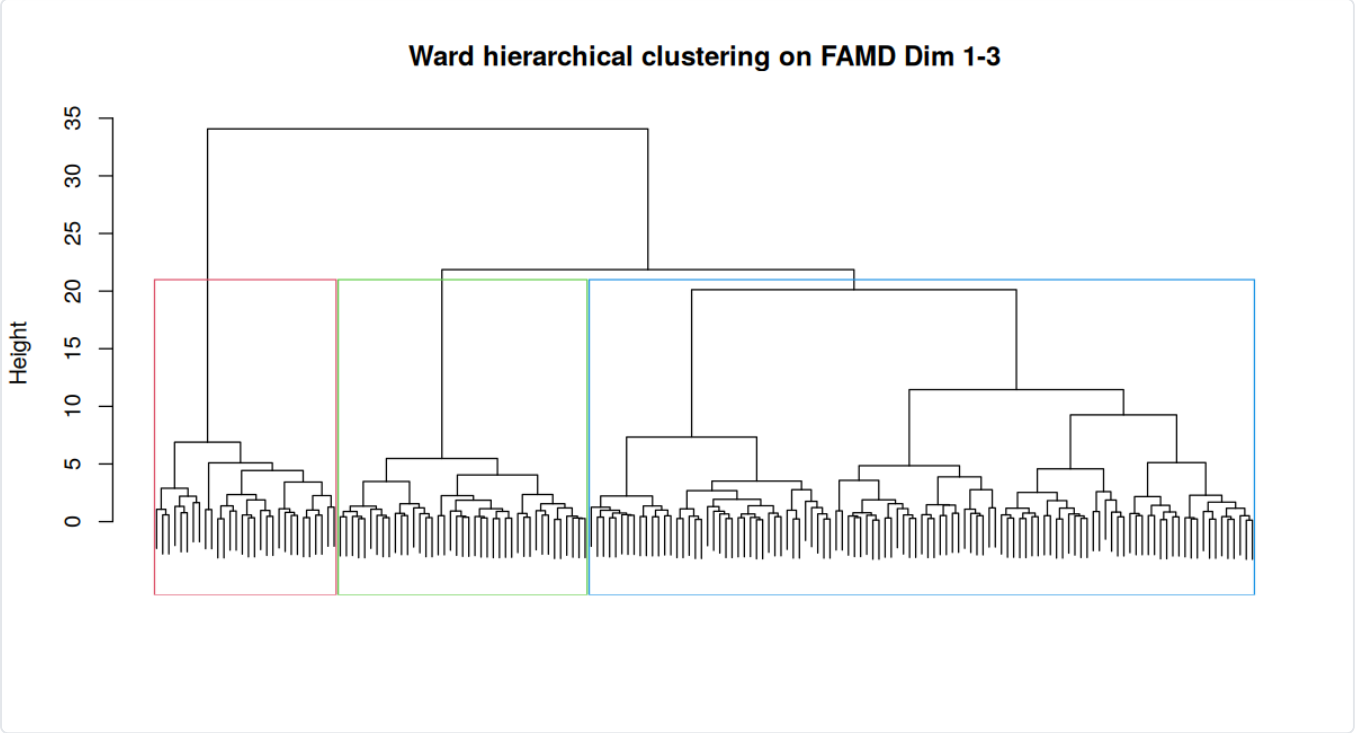
Part D – විචාරශීලී චින්තනය

1. **Contribution එදිරිව cos2:** contribution කියන්නේ category එකක් axis එකක් කොච්චර **හදනවද** (axis එකට වැදගත්කම); cos2 කියන්නේ ඒ category එක axis එකෙන් කොච්චර **හොඳින් පෙන්නනවද** (ගුණාත්මකභාවය). දුර්ලභ category එකක් ගොඩක් contribute කළත් අර්ධව විතරක් නිරූපණය වෙන්න පුළුවන්, origin එකට ළඟ පොදු category එකක් හොඳින් නිරූපණය වුණත් අඩුවෙන් contribute කරන්න පුළුවන්.
2. **Origin එකෙන් ඈත:** ඒකට සාමාන්‍ය ශිෂ්‍යයාට වඩා ගොඩක් වෙනස් profile එකක් තියෙනවා, ඒ නිසා බොහෝ විට dimension එකක් නිර්වචනය කරන්න උදව් වෙනවා, සුවිශේෂී කණ්ඩායමක් පෙන්නනවා (උදා: Last Minute, Attendance_Rare).
3. **දුර්ලභ categories:** ඒවා origin එකෙන් ඈතට තල්ලු වෙලා, ස්වල්ප දෙනෙක් මත පදනම්ව ලොකු contributions ලබාගන්න පුළුවන්. ඒවායේ පිහිටීම අස්ථිරයි (ශිෂ්‍යයන් කිහිප දෙනෙක්ට ඒක වෙනස් කරන්න පුළුවන්), ඒ නිසා පරිස්සමෙන් අර්ථකථනය කරන්න; ඉතා දුර්ලභ categories ඒකාබද්ධ කිරීම සලකා බලන්න.
4. **Dimensions දෙක "data එක" නෙවෙයි:** මෙතන ඒවා inertia වලින් 23.5% (MCA) හෝ 25.7% (FAMD) ක් විතරයි තියාගන්නේ. ව්‍යුහයෙන් ගොඩක් පසු dimensions වල තියෙනවා; 2-D map එක සරල කළ දසුනක් විතරයි.
5. **Dimension reduction prediction එකට හානි කරන විට:** උදා: වැදගත් predictor එකක් (Hackathons හෝ දුර්ලභ category එකක් වගේ) අඩු variance එකක් තියෙන නිසා අපි අතහරින පසු dimension එකකට වැටෙනකොට රැකියාව predict කිරීම. PCA/MCA/FAMD axes තෝරන්නේ **variance** අනුව මිසක් ප්‍රතිඵලය එක්ක ඇති සම්බන්ධය අනුව නෙවෙයි, ඒ නිසා prediction එකට ඕන තොරතුරු විසි වෙන්න පුළුවන්.

Optional challenge – clustering ප්‍රතිඵල රඳා පවතින්නේ ඇයි...

- **තියාගත් dimensions ගණන:** dims 2 vs 3 vs 5 මිනිසුන් අතර වෙනස් දුර දෙනවා (dims වැඩි කළාම විස්තර වැඩි වෙනවා, noise ත් වැඩි වෙනවා), ඒ නිසා clusters වෙනස් වෙනවා.
- **Scaling / weighting:** දුර රඳා පවතින්නේ හැම coordinate එකකම පරිමාණය මත; Dim 1 ට ලොකුම පැතිරීම තියෙන නිසා ඒක ආධිපත්‍යය ගන්නවා. Weights වෙනස් කිරීම (උදා: coordinates standardise කිරීම, හෝ FAMD වල categorical/quantitative සමබරතාව) clusters වෙනස් කරනවා.

- **තෝරාගත් clusters ගණන:** k-means හැමවිටම හරියටම කණ්ඩායම් k දෙනවා; elbow plot එකක් (within-SS: k = 1–4 සඳහා 1393, 812, 541, 315, …) හෝ silhouette, සහ විෂය දැනුම භාවිතා කරන්න.
- **නිරූපණයේ ගුණාත්මකභාවය:** අඩු cos2 ඇති individuals තියාගත් dimensions වල දුර්වලව පෙන්නන නිසා ඔවුන්ගේ cluster සාමාජිකත්වය අඩුවෙන් විශ්වාසදායකයි.



සැසඳීම: Dims 1–3 මත Ward hierarchical clustering (කණ්ඩායම් 3කට කැපුවා: 41, 109, 30)

9. Cluster analysis හැඳින්වීම

Cluster analysis කියන්නේ unsupervised learning: **දුර (distance)** මිනුමක් භාවිතා කරලා සමාන observations කණ්ඩායම් (clusters) වලට දානවා. Lecture එක කුඩා උදාහරණයකින් පටන් ගත්තා.

9.1 Data

```
names <- list(c("g1","g2","g3","g4","g5"), c("p1","p2"))
sl.clus.dat <- matrix(c(1,1, 1,1.1, 3,2, 3,2.3, 5,5), ncol = 2,
                      byrow = TRUE, dimnames = names)
plot(sl.clus.dat)
plot(sl.clus.dat, type = "n", xlim = c(0,6), ylim = c(0,6))
text(sl.clus.dat, labels = row.names(sl.clus.dat))
```

- Variables 2ක් (p1, p2) ඇති points 5ක් (g1 … g5). `byrow = TRUE` matrix එක පේළියෙන් පේළිය පුරවනවා; `dimnames` පේළි සහ column නම් දෙනවා.
- `type = "n"` හිස් plot එකක් අඳිනවා (points නැහැ), ඊට පස්සේ `text()` හැම point එකකම නම එහි පිහිටීමේ ලියනවා.

	p1	p2
g1	1	1.0
g2	1	1.1
g3	3	2.0
g4	3	2.3
g5	5	5.0

9.2 Distance matrix එක

```
print(dist(sl.clus.dat, method = "euclidean"), digits = 3)
```

Euclidean දුර = $\sqrt{((p1_i - p1_j)^2 + (p2_i - p2_j)^2)}$. උදාහරණය g1–g3: $\sqrt{(2^2 + 1^2)} = \sqrt{5} = 2.24$.

	g1	g2	g3	g4
g2	0.10			
g3	2.24	2.19		
g4	2.39	2.33	0.30	
g5	5.66	5.59	3.61	3.36

9.3 Hierarchical clustering – single සහ complete linkage

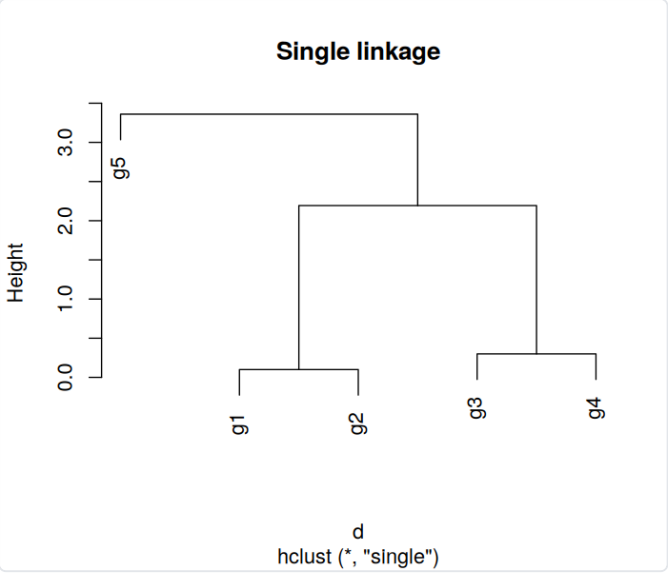
```
d = dist(sl.clus.dat, method = "euclidean")
hclust_out = hclust(d, method = "single")
hclust_out
plot(hclust_out)

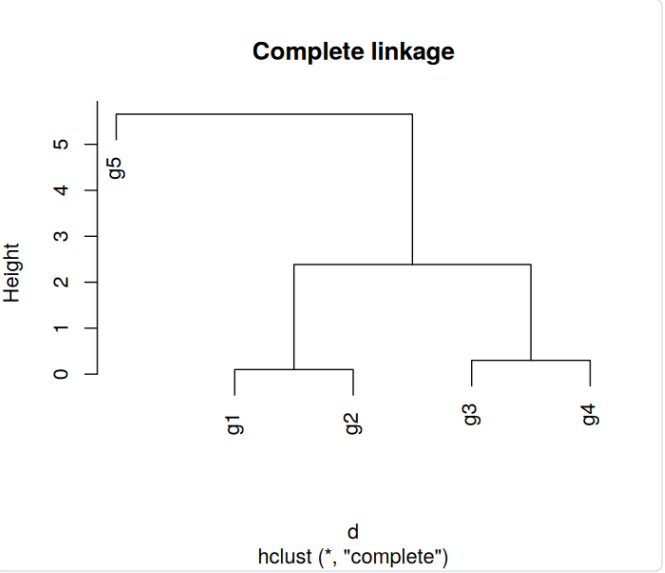
hclust_out_complete = hclust(d, method = "complete")
plot(hclust_out_complete)
```

Agglomerative hierarchical clustering: හැම point එකක්ම තමන්ගේම cluster එකක් විදිහට පටන් අරන්, එක cluster එකක් ඉතිරි වෙනකම් **ළඟම clusters දෙක නැවත නැවත එකතු කරනවා**. Clusters දෙකක් අතර දුර තීරණය කරන්නේ **linkage** එක:

- **Single linkage** = සාමාජිකයන් දෙදෙනෙකු අතර **අවම** දුර (ළඟම අසල්වාසීන්).
- **Complete linkage** = සාමාජිකයන් දෙදෙනෙකු අතර **උපරිම** දුර (ඈතම අසල්වාසීන්).

පියවර	Single linkage	Complete linkage
1	g1, g2 එකතු කරනවා **0.10** දී	g1, g2 එකතු කරනවා **0.10** දී
2	g3, g4 එකතු කරනවා **0.30** දී	g3, g4 එකතු කරනවා **0.30** දී
3	{g1,g2}–{g3,g4} = min(2.24, 2.39, 2.19, 2.33) = **2.19** → එකතු කරනවා	{g1,g2}–{g3,g4} = max(2.24, 2.39, 2.19, 2.33) = **2.39** → එකතු කරනවා
4	g5 සිට ඉතිරිය = min(5.66, 5.59, 3.61, 3.36) = **3.36** → එකතු කරනවා	g5 සිට ඉතිරිය = max(5.66, 5.59, 3.61, 3.36) = **5.66** → එකතු කරනවා





Dendrogram එක (ගස) එකතු වුණු පිළිවෙළ පෙන්නනවා; හැම එකතු වීමකම උස clusters එකතු කළ දුර. මෙතන linkage දෙකෙන්ම එකම පිළිවෙළ ලැබෙනවා, නමුත් අන්තිම එකතු වීම් දෙකේ උස වෙනස් (2.19/3.36 එදිරිව 2.39/5.66). තෝරාගත් උසකින් ගස කැපුවාම clusters ලැබෙනවා, උදා: {g1,g2}, {g3,g4}, {g5}.

> **ලබන සතියේ**
> අලුත් උදාහරණයක් මත වෙනස් distances සහ linkages (උදා: Manhattan, average, Ward) run කරනවා.

10. සාරාංශය සහ සම්පූර්ණ R workflow එක

ප්‍රධාන කරුණු

- PCA → quantitative; CA → එක contingency table එකක්; **MCA → categorical කිහිපයක්**; **FAMD → mixed**; MFA → blocks.
- Data සූදානම් කරන්න: IDs row names වලට, ඔක්කොම categorical columns **factors** ලෙස, frequencies බලන්න (දුර්ලභ categories ගැන අවධානයෙන්).
- Supplementary variables project කරනවා නමුත් axes **හදන්නේ නැහැ** – performance හෝ employment වගේ ප්‍රතිඵල check කරන්න හොඳයි.
- කියවන්න: **eigenvalues/scree** → dims කීයද; **contributions** → axis එකක් හදන්නේ මොනවද; **cos2** → කොච්චර හොඳින් පෙන්නනවද; **v.test/dimdesc** → වැදගත්කම සහ ස්වයංක්‍රීය විස්තරය.
- MCA ප්‍රතිශත ස්වභාවයෙන්ම අඩුයි – ස්වයංක්‍රීය 80% නීතිය භාවිතා කරන්න එපා.
- හැම axis එකකටම අර්ථවත් **නමක්** දෙන්න; සම්බන්ධය ≠ හේතුඵලය.
- අඩු කළ coordinates (`$ind$coord`) **clustering** සඳහා යොදන්න පුළුවන්; ප්‍රතිඵල රඳා පවතින්නේ තියාගත් dims, scaling, k සහ නිරූපණ ගුණාත්මකභාවය මත.
- Hierarchical clustering: distance matrix → linkage (single = min, complete = max) → dendrogram.

```r
## ---------- MCA ----------
dat <- read.csv("student_learning_profiles_categorical.csv", stringsAsFactors = TRUE)
rownames(dat) <- dat$Student_ID;  dat$Student_ID <- NULL
dat[] <- lapply(dat, as.factor)
library(FactoMineR); library(factoextra)
sup_idx <- which(names(dat) %in% c("Programme", "Performance_Band"))
res_mca <- MCA(dat, quali.sup = sup_idx, ncp = 5, graph = FALSE)
res_mca$eig;  fviz_eig(res_mca, addlabels = TRUE)
fviz_mca_var(res_mca, choice = "var.cat", repel = TRUE)
fviz_contrib(res_mca, choice = "var", axes = 1, top = 15)
fviz_cos2(res_mca, choice = "var", axes = 1, top = 15)
fviz_mca_ind(res_mca, geom = "point", col.ind = "cos2")
res_mca$quali.sup$coord;  plot(res_mca, invisible = c("ind", "var"), hab = "quali")
dimdesc(res_mca, axes = 1:2)
student_coordinates <- as.data.frame(res_mca$ind$coord)

## ---------- FAMD ----------
dat <- read.csv("graduate_employability_mixed.csv", stringsAsFactors = TRUE)
rownames(dat) <- dat$Graduate_ID;  dat$Graduate_ID <- NULL
sup_idx <- which(names(dat) == "Employment_Status")
res_famd <- FAMD(dat, sup.var = sup_idx, ncp = 5, graph = FALSE)
res_famd$eig;  fviz_eig(res_famd, addlabels = TRUE)
fviz_famd_var(res_famd, choice = "quanti.var", repel = TRUE)
fviz_famd_var(res_famd, choice = "quali.var",  repel = TRUE)
fviz_contrib(res_famd, choice = "var", axes = 1, top = 15)
fviz_famd_ind(res_famd, geom = "point", col.ind = "cos2")
plot(res_famd, choix = "ind", invisible = c("ind", "quali"))   # supplementary
dimdesc(res_famd, axes = 1:2)
graduate_coordinates <- as.data.frame(res_famd$ind$coord)

## ---------- Hierarchical clustering ----------
d <- dist(sl.clus.dat, method = "euclidean")
plot(hclust(d, method = "single"));  plot(hclust(d, method = "complete"))
```

වැඩිදුර කියවීම: FactoMineR reference manual – cran.r-project.org/web/packages/FactoMineR/FactoMineR.pdf; factoextra reference manual – cran.r-project.org/web/packages/factoextra/factoextra.pdf.